

《统计计算》期末突击复习资料

(第 1-7 章 · 知识点详解 + 考点题型 + 模拟题)

参考课件与高惠璇《统计计算》整理

目录

1 预备知识：概率论与数理统计基础速览	4
1.1 随机变量、分布函数与密度函数	4
1.2 期望、方差与协方差	4
1.3 常用分布速查表	5
1.4 三大抽样分布与统计量	5
1.5 大数定律与中心极限定理（蒙特卡洛方法的理论基础）	5
1.6 点估计、置信区间与假设检验回顾	6
2 第 1 章 一维（非均匀）随机数的生成	6
2.1 总览：这一章在干什么	6
2.2 逆变换法（最重要、最常考）	7
2.3 舍选抽样法（接受—拒绝法）	7
2.4 变换抽样法	8
2.5 复合抽样法	9
2.6 近似抽样法	9
2.7 离散分布随机数的抽样	9
2.8 本章考点与题型	10
3 第 2 章 随机向量随机数的抽样方法	10
3.1 总览	10
3.2 变换抽样法（含 Jacobi 行列式）	10
3.3 条件分布法（最常考）	11
3.4 多维舍选抽样法	11
3.5 离散随机向量：条件分布法与多项分布	11
3.6 本章考点与题型	12
4 第 3 章 参数估计的统计计算	12
4.1 总览	12
4.2 用 MC 估计估计量的期望与方差	12
4.3 置信区间回顾与覆盖率的 MC 估计	13
4.3.1 单总体正态均值的置信区间	13

4.3.2	总体比例的（渐近）置信区间	13
4.3.3	两总体的置信区间	13
4.3.4	置信区间覆盖率的 MC 估计	13
4.4	本章考点与题型	14
5	第 4 章 假设检验的统计计算	14
5.1	总览	14
5.2	MC 估计第一类错误概率与功效	14
5.3	单样本拟合优度检验	15
5.3.1	χ^2 拟合优度检验（总体分布的卡方检验）	15
5.3.2	单样本 K-S 检验	15
5.3.3	随机性检验：变号检验与游程检验	15
5.4	两样本非参数检验	15
5.4.1	Mann-Whitney U 检验（曼—惠特尼）	15
5.4.2	两样本 K-S 检验	16
5.4.3	两样本游程检验	16
5.5	独立性检验	16
5.5.1	列联表 χ^2 检验	16
5.5.2	相关系数检验	16
5.6	本章考点与题型	16
6	第 5 章 减小方差的计算方法（方差缩减技术）	17
6.1	总览与动机	17
6.2	随机投点法与平均值法	17
6.3	对偶变量法（对照变量法）	17
6.4	控制变量法	18
6.5	条件期望法（Rao-Blackwell 化）	18
6.6	重要抽样法（importance sampling）	18
6.7	分层抽样法	19
6.8	随机数重复使用（公共随机数法）	19
6.9	本章考点与题型	19
7	第 6 章 重抽样方法（Bootstrap 与 Jackknife）	19
7.1	总览	19
7.2	从蒙特卡洛到 Bootstrap	20
7.3	Bootstrap 估计标准误与偏差	20
7.4	Jackknife（刀切法）	20
7.5	Bootstrap 置信区间	21
7.6	本章考点与题型	21

8 第 7 章 EM 算法	21
8.1 总览与动机	21
8.2 算法框架（必背）	22
8.3 经典例子一：两硬币问题	22
8.4 经典例子二：多项分布参数的 EM	23
8.5 经典例子三：正态分布缺失数据	23
8.6 经典例子四：混合模型（重点）	23
8.7 本章考点与题型	23
9 模拟试题（附详细解答）	24

1 预备知识：概率论与数理统计基础速览

本章是后面所有内容的”地基”。统计计算的核心思想只有一句话：用计算机生成大量随机样本，再用样本的频率/均值去近似概率/期望。要看懂这件事，需要先把下面几个基础概念弄扎实。

1.1 随机变量、分布函数与密度函数

核心概念

- **分布函数 (CDF)**: $F(x) = \mathbb{P}(X \leq x)$ 。单调不减、右连续, $F(-\infty) = 0$, $F(+\infty) = 1$ 。任何随机变量都有分布函数。
- **密度函数 (pdf)**: 连续型随机变量满足 $F(x) = \int_{-\infty}^x f(t) dt$, 即 $f(x) = F'(x)$ 。直观理解: $f(x)\Delta x \approx \mathbb{P}(x < X \leq x + \Delta x)$, 密度大的地方取值”更密集”。
- **分布律 (pmf)**: 离散型随机变量用 $p_k = \mathbb{P}(X = x_k)$ 描述, $\sum_k p_k = 1$ 。

1.2 期望、方差与协方差

$$\mathbb{E}(X) = \int x f(x) dx \quad (\text{连续型}), \quad \mathbb{E}(X) = \sum_k x_k p_k \quad (\text{离散型}).$$

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}X)^2] = \mathbb{E}(X^2) - (\mathbb{E}X)^2.$$

常用性质 (考试与推导中反复用到):

- 线性性: $\mathbb{E}(aX + bY) = a\mathbb{E}X + b\mathbb{E}Y$ (无需独立)。
- $\text{Var}(aX + b) = a^2\text{Var}(X)$ 。
- $\text{Var}(X + Y) = \text{Var}X + \text{Var}Y + 2\text{Cov}(X, Y)$; 若 X, Y 独立, 则 $\text{Cov}(X, Y) = 0$ 。
- $\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}X \mathbb{E}Y$; 相关系数 $\rho = \text{Cov}(X, Y) / \sqrt{\text{Var}X \text{Var}Y} \in [-1, 1]$ 。

注. 第 5 章方差缩减技术的全部原理就建立在 $\text{Var}(\frac{X+Y}{2}) = \frac{1}{4}(\text{Var}X + \text{Var}Y + 2\text{Cov}(X, Y))$ 这个公式上: 若能让 $\text{Cov}(X, Y) < 0$, 平均后的方差就比独立样本更小。

1.3 常用分布速查表

分布	密度/分布律	期望	方差
均匀 $U(a, b)$	$f = \frac{1}{b-a}, a < x < b$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
指数 $\text{Exp}(\lambda)$	$f = \lambda e^{-\lambda x}, x > 0$	$1/\lambda$	$1/\lambda^2$
正态 $N(\mu, \sigma^2)$	$f = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	μ	σ^2
Gamma(α, γ)	$f = \frac{\gamma^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\gamma x}, x > 0$	α/γ	α/γ^2
Beta(α, β)	$f = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}, 0 < x < 1$	$\frac{\alpha}{\alpha+\beta}$	$\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$
二项 $B(n, p)$	$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$	np	$np(1-p)$
泊松 $P(\lambda)$	$\mathbb{P}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$	λ	λ
几何 $\text{Geo}(p)$	$\mathbb{P}(X = k) = (1-p)^{k-1} p$	$1/p$	$\frac{1-p}{p^2}$

几个重要关系（生成随机数时经常用来“借力”）：

- $\text{Exp}(\lambda) = \text{Gamma}(1, \lambda)$ ；Gamma 可加性：独立的 $\text{Gamma}(\alpha_i, \gamma)$ 之和服从 $\text{Gamma}(\sum \alpha_i, \gamma)$ 。
- $\chi^2(n) = \text{Gamma}(n/2, 1/2)$ ；若 $Z_i \stackrel{iid}{\sim} N(0, 1)$ ，则 $\sum_{i=1}^n Z_i^2 \sim \chi^2(n)$ 。
- 若 $\xi \sim \text{Gamma}(\alpha, \gamma)$ ，则 $\xi/a \sim \text{Gamma}(\alpha, a\gamma)$ （尺度变换）。
- 若 $Z \sim N(0, 1)$ ，则 $\mu + \sigma Z \sim N(\mu, \sigma^2)$ 。

1.4 三大抽样分布与统计量

设 $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$ ，样本均值 $\bar{X} = \frac{1}{n} \sum X_i$ ，样本方差 $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ 。则

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1), \quad \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1),$$

且 $\bar{X}$ 与 S^2 独立。两个独立卡方变量标准化之比服从 F 分布： $\frac{\chi^2(m)/m}{\chi^2(n)/n} \sim F(m, n)$ 。

1.5 大数定律与中心极限定理（蒙特卡洛方法的理论基础）

为什么“用样本均值估期望”是合理的？

设 $X_1, X_2, \dots$ 独立同分布， $\mathbb{E}X_i = \mu$ ， $\text{Var}X_i = \sigma^2 < \infty$ 。

- **大数定律 (LLN)**: $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu$ 。
即样本量足够大时，样本均值几乎必然接近真实期望——这保证了蒙特卡洛估计的**相合性**。
- **中心极限定理 (CLT)**: $\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1)$ 。
即误差约为 $O(1/\sqrt{n})$ 量级，且近似服从正态分布——这给出了蒙特卡洛估计的**精度**与

置信区间。

重要结论：蒙特卡洛误差的标准差为 $\sigma/\sqrt{n}$ 。想把精度提高 10 倍，样本量需要扩大 100 倍；或者保持 n 不变、想办法**减小** σ ——这正是第 5 章方差缩减的动机。

1.6 点估计、置信区间与假设检验回顾

- **点估计：**用统计量 $\hat{\theta}(X_1, \dots, X_n)$ 估计未知参数 θ 。构造方法主要有**矩估计法**和**极大似然估计法 (MLE)**。评价标准：
 - 无偏性： $\mathbb{E}(\hat{\theta}) = \theta$ ；偏差 $\text{Bias}(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta$ 。
 - 有效性：同为无偏估计时方差更小者更有效。
 - 相合性： $n \rightarrow \infty$ 时 $\hat{\theta} \xrightarrow{P} \theta$ 。
 - 综合指标——均方误差： $\text{MSE}(\hat{\theta}) = \mathbb{E}(\hat{\theta} - \theta)^2 = \text{Bias}^2 + \text{Var}(\hat{\theta})$ 。
- **置信区间：**随机区间 $[\hat{\theta}_L, \hat{\theta}_U]$ 满足 $\mathbb{P}(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) = 1 - \alpha$ 。 $1 - \alpha$ 称置信水平。构造的通用套路是找**枢轴量**（含 θ 但分布已知的量）。
- **假设检验：**原假设 H_0 vs 备择假设 H_1 。
 - **第一类错误**（弃真）： H_0 为真却拒绝，概率记 α （显著性水平）。
 - **第二类错误**（取伪）： H_0 为假却接受，概率记 β 。
 - **功效 (power)**： $1 - \beta = \mathbb{P}(\text{拒绝 } H_0 \mid H_1 \text{ 成立})$ ，衡量检验“识别假原假设”的能力。
- **似然函数：**样本 $x_1, \dots, x_n$ 给定后， $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$ 。MLE 就是使 $L(\theta)$ （等价地 $\log L$ ）最大的 θ 。第 7 章 EM 算法处理的是“数据不完整时没法直接最大化似然”的情形。

2 第 1 章 一维（非均匀）随机数的生成

2.1 总览：这一章在干什么

计算机能直接产生的只有 $U(0, 1)$ 均匀随机数（由线性同余等伪随机数发生器产生）。本章解决：**如何把均匀随机数加工成服从任意目标分布 $F(x)$ 的随机数**。五大方法：**逆变换法**、**舍选（接受—拒绝）法**、**变换法**、**复合法**、**近似法**；以及离散分布的抽样。

定义 2.1 (随机数). 设 X 有分布函数 $F(x)$ ，从 F 中随机抽样得到的序列 $\{x_i\}$ 称为该分布的随机数序列， x_i 称为分布 $F(x)$ 的随机数。

2.2 逆变换法(最重要、最常考)

定理 1.1.1 (逆变换法原理)

设连续型随机变量 η 的分布函数 $F(x)$ 连续且严格单调上升, 反函数 F^{-1} 存在。则

1. $F(\eta) \sim U(0, 1)$;
2. 若 $U \sim U(0, 1)$, 则 $F^{-1}(U)$ 的分布函数恰为 $F(x)$ 。

证明 (必会!) . (1) 记 $G(u) = \mathbb{P}(F(\eta) \leq u)$ 。当 $u \in [0, 1]$ 时, 由 F 严格单调, $G(u) = \mathbb{P}(\eta \leq F^{-1}(u)) = F(F^{-1}(u)) = u$; $u < 0$ 时 $G = 0$, $u > 1$ 时 $G = 1$ 。这正是 $U(0, 1)$ 的分布函数。

(2) $\mathbb{P}(F^{-1}(U) \leq x) = \mathbb{P}(U \leq F(x)) = F(x)$ (因为 U 均匀且 $F(x) \in [0, 1]$)。□

算法步骤

1. 产生 $u \sim U(0, 1)$;
2. 计算 $x = F^{-1}(u)$, 则 x 即为目标分布的随机数。

经典例子 (务必熟练手算):

- 指数分布 $\text{Exp}(\lambda)$: $F(x) = 1 - e^{-\lambda x}$, 解 $u = 1 - e^{-\lambda x}$ 得

$$x = -\frac{1}{\lambda} \ln(1 - u) \quad (\text{由于 } 1 - U \stackrel{d}{=} U, \text{ 也常写 } x = -\frac{1}{\lambda} \ln u).$$

- 柯西分布: $F(x) = \frac{1}{2} + \frac{1}{\pi} \arctan x \Rightarrow x = \tan(\pi(u - \frac{1}{2}))$ 。
- 威布尔分布 $F(x) = 1 - e^{-(x/\beta)^\alpha} \Rightarrow x = \beta(-\ln u)^{1/\alpha}$ 。

易错点

逆变换法的局限: 很多分布(正态、Gamma、Beta 等)的分布函数没有显式表达式, F^{-1} 无法解析求出, 因此**不能直接用逆变换法**, 需要下面的方法。

2.3 舍选抽样法(接受—拒绝法)

基本思想

目标密度 $p(x)$ 不好直接抽, 就找一个**容易抽样的**”建议密度” $f(x)$ 和常数 $M (\geq 1)$, 使

$$p(x) \leq M f(x) \quad \text{对一切 } x,$$

即 p 被 Mf ”罩住”。记 $h(x) = \frac{p(x)}{M f(x)} \in [0, 1]$ 。

算法步骤

1. 由 $f(x)$ 产生随机数 y ;
2. 产生 $u \sim U(0, 1)$ (与 y 独立);
3. 若 $u \leq h(y) = \frac{p(y)}{Mf(y)}$, 则**接受** $x = y$; 否则**舍弃**, 返回第 1 步。

被接受的 x 恰好服从密度 $p(x)$ 。每次试验被接受的概率为 $1/M$, 平均需要 M 次试验得到一个有效样本, 故 M **越小(越接近 1) 效率越高**。

注. 直观理解: 在曲线 $Mf(x)$ 下方均匀撒点, 只保留落在 $p(x)$ 下方的点, 这些点的横坐标自然按 p 的”高矮”分布。

例 1 (Beta 分布): 生成 $\text{Beta}(\alpha, \beta)$ ($\alpha, \beta > 1$)。取 $f(x) = 1$ (即 $U(0, 1)$ 密度), 因 Beta 密度在众数 $x_0 = \frac{\alpha-1}{\alpha+\beta-2}$ 处最大, 取 $M = p(x_0)$, 则算法为: 产生 $y, u \sim U(0, 1)$, 若 $u \leq p(y)/M$ 接受。

例 2 (半正态法生成标准正态): 对 $|Z|$ 的密度 $p(x) = \sqrt{\frac{2}{\pi}} e^{-x^2/2}$ ($x > 0$), 取建议密度 $f(x) = e^{-x}$ ($\text{Exp}(1)$), 可算得

$$\frac{p(x)}{f(x)} = \sqrt{\frac{2}{\pi}} e^{x-x^2/2} \leq \sqrt{\frac{2e}{\pi}} =: M \approx 1.32,$$

(最大值在 $x = 1$ 处取得)。接受后再以等概率 $\pm$ 随机赋符号即得 $N(0, 1)$ 。

例 3 (Gamma 分布, $\alpha > 1$): 生成 $\text{Gamma}(\alpha, 1)$ 可取 $\text{Exp}(1/\alpha)$ 作建议分布 (均值匹配), 再按舍选法接受。若需 $\text{Gamma}(\alpha, \gamma)$, 先生成 $\eta \sim \text{Gamma}(\alpha, 1)$, 则 $\eta/\gamma \sim \text{Gamma}(\alpha, \gamma)$ 。

易错点

- M 必须满足 $M \geq \sup_x p(x)/f(x)$, 通常通过求导找 p/f 的最大值确定最优 M 。
- 建议密度 f 的支撑必须覆盖 p 的支撑 ($p(x) > 0$ 处必须 $f(x) > 0$)。
- 无界区间上不能取”均匀建议分布”, 因为常数函数在 $(-\infty, \infty)$ 上积分发散。

2.4 变换抽样法

利用已知分布之间的函数关系: ”会抽 ξ , 且 $\eta = g(\xi)$, 则把 ξ 的样本代入 g 即得 η 的样本”。

重要例子:

- **Box-Muller 法生成正态:** 设 $U_1, U_2 \stackrel{iid}{\sim} U(0, 1)$, 则

$$Z_1 = \sqrt{-2 \ln U_1} \cos(2\pi U_2), \quad Z_2 = \sqrt{-2 \ln U_1} \sin(2\pi U_2)$$

是两个独立的 $N(0, 1)$ 随机数。再令 $X = \mu + \sigma Z$ 得 $N(\mu, \sigma^2)$ 。

- **卡方分布:** $Z_1, \dots, Z_n \stackrel{iid}{\sim} N(0, 1) \Rightarrow \sum Z_i^2 \sim \chi^2(n)$ 。原理: $Z_i^2 \sim \text{Gamma}(1/2, 1/2)$, 由 Gamma 可加性求得 $\text{Gamma}(n/2, 1/2) = \chi^2(n)$ 。
- **Gamma 尺度变换:** $\xi \sim \text{Gamma}(\alpha, \gamma) \Rightarrow \xi/a \sim \text{Gamma}(\alpha, a\gamma)$ 。例如生成 $\text{Gamma}(1/2, 3)$: 先取 $Z \sim N(0, 1)$, 则 $Z^2 \sim \text{Gamma}(1/2, 1/2) = \chi^2(1)$, 再令 $\eta = Z^2/6 \sim \text{Gamma}(1/2, 3)$ 。

- **对数正态**: $Z \sim N(\mu, \sigma^2) \Rightarrow e^Z \sim \text{LogNormal}(\mu, \sigma^2)$ 。
- **t 与 F**: $t(n) = \frac{N(0, 1)}{\sqrt{\chi^2(n)/n}}$, $F(m, n) = \frac{\chi^2(m)/m}{\chi^2(n)/n}$ (分子分母独立)。

2.5 复合抽样法

若目标密度可写成混合形式

$$p(x) = \sum_{i=1}^k w_i p_i(x), \quad w_i > 0, \quad \sum w_i = 1,$$

其中每个 p_i 都容易抽样, 则:

算法步骤

1. 以概率 $w_1, \dots, w_k$ 随机选一个分支 i (离散抽样);
2. 从 $p_i(x)$ 中抽一个数作为输出。

连续混合同理: $p(x) = \int p(x|y)g(y)dy$ 时, 先抽 $y \sim g$, 再抽 $x \sim p(\cdot|y)$ 。

2.6 近似抽样法

利用中心极限定理近似生成正态随机数: 取 $U_1, \dots, U_{12} \stackrel{iid}{\sim} U(0, 1)$, 因 $\mathbb{E}U_i = \frac{1}{2}$, $\text{Var}U_i = \frac{1}{12}$, 故

$$Z = \sum_{i=1}^{12} U_i - 6 \approx N(0, 1).$$

优点是简单, 缺点是只是近似 (尾部精度差), 现代多用 Box-Muller 或舍选法。

2.7 离散分布随机数的抽样

离散逆变换法 (查表法)

设 $\mathbb{P}(X = x_k) = p_k$, 累积概率 $q_k = p_1 + \dots + p_k$ 。产生 $u \sim U(0, 1)$, 找到使 $q_{k-1} < u \leq q_k$ 的 k , 输出 x_k 。正确性: $\mathbb{P}(\text{输出} x_k) = q_k - q_{k-1} = p_k$ 。

常见离散分布:

- **两点分布** $B(1, p)$: $u \leq p$ 输出 1, 否则输出 0。
- **二项分布** $B(n, p)$: 生成 n 个两点分布随机数求和。
- **几何分布**: 可由逆变换直接得 $X = \lceil \ln u / \ln(1-p) \rceil$, 即“截尾的指数分布”。
- **泊松分布** $P(\lambda)$: 利用与指数分布的关系——不断累乘均匀数, $X = \min\{n : \prod_{i=1}^{n+1} u_i < e^{-\lambda}\}$ (即指数间隔的计数)。

2.8 本章考点与题型

高频题型

1. 证明逆变换法定理（送分题，背证明）。
2. 给定 $F(x)$ 写出逆变换抽样公式与步骤：如指数、柯西、威布尔，或给个分段密度先积分求 F 、再求反函数。
3. 设计舍选算法：给目标密度 p 和建议密度 f ，求最优常数 $M = \sup p/f$ （求导），写出算法步骤，并指出接受概率为 $1/M$ 。典型：Beta、半正态、Gamma。
4. 变换法：写出 Box-Muller 公式；用 $N(0, 1) \rightarrow \chi^2(n) \rightarrow \text{Gamma}$ 的链条生成指定 Gamma 随机数。
5. 离散分布抽样：写出查表法步骤并说明正确性。

3 第2章 随机向量随机数的抽样方法

3.1 总览

把第1章的思想推广到多维：生成服从联合分布 $f(x_1, \dots, x_p)$ 的随机向量。三种方法：变换法、条件分布法、舍选法；离散随机向量用条件分布法（典型：多项分布）。

3.2 变换抽样法（含 Jacobi 行列式）

密度变换公式（基础铺垫）

设 p 维随机向量 $\xi = (\xi_1, \dots, \xi_p)$ 有密度 $f(x_1, \dots, x_p)$ ，作可逆变换 $\eta = g(\xi)$ ，逆变换 $\xi = g^{-1}(\eta)$ ，则 η 的密度为

$$p(\mathbf{y}) = f(g^{-1}(\mathbf{y})) \cdot |J|, \quad J = \det\left(\frac{\partial x_i}{\partial y_j}\right)$$

即“原密度 $\times$ 逆变换的 Jacobi 行列式绝对值”。

核心例子：二维正态 $N_2(\mu, \Sigma)$ 的生成。 设 $\xi_1, \xi_2 \stackrel{iid}{\sim} N(0, 1)$ ，记

$$\mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}.$$

令

$$\eta_1 = \mu_1 + \sigma_1\xi_1, \quad \eta_2 = \mu_2 + \sigma_2(\rho\xi_1 + \sqrt{1-\rho^2}\xi_2),$$

则 $(\eta_1, \eta_2) \sim N_2(\mu, \Sigma)$ 。（验证： $\mathbb{E}\eta_i = \mu_i$ ， $\text{Var}\eta_i = \sigma_i^2$ ， $\text{Cov}(\eta_1, \eta_2) = \sigma_1\sigma_2\rho$ ，且线性组合保持正态。）

一般 p 维正态：求 Σ 的 Cholesky 分解 $\Sigma = LL^T$ （ L 下三角），取 $\mathbf{Z} = (Z_1, \dots, Z_p)^T$ 为独立标准正态，则

$$\mathbf{X} = \mu + L\mathbf{Z} \sim N_p(\mu, \Sigma).$$

原理: $\text{Cov}(\mathbf{X}) = L \text{Cov}(\mathbf{Z}) L^T = LL^T = \Sigma$ 。

3.3 条件分布法 (最常考)

基本思想: 把联合分布拆成”链”

$$f(x_1, x_2, \dots, x_p) = f_1(x_1) f_2(x_2 | x_1) \cdots f_p(x_p | x_1, \dots, x_{p-1}).$$

于是只要会抽每个一维条件分布, 就能逐个坐标地生成整个向量。

算法步骤

1. 从边际分布 $f_1(x_1)$ 抽 x_1 ;
2. 从条件分布 $f_2(x_2 | x_1)$ 抽 x_2 ;
3. ...依此类推, 直到抽出 x_p 。输出 $(x_1, \dots, x_p)$ 。

例 (二维正态的条件分布法): $X = (X_1, X_2) \sim N_2(\boldsymbol{\mu}, \Sigma)$ 时,

$$X_1 \sim N(\mu_1, \sigma_1^2), \quad X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right).$$

先抽 x_1 , 再代入条件正态抽 x_2 , 结果与变换法一致。**多维正态的条件分布公式** (需记): 把 $\mathbf{X}, \boldsymbol{\mu}, \Sigma$ 分块为 $\mathbf{X} = \begin{pmatrix} X_1 \\ \mathbf{X}_2 \end{pmatrix}$, $\Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$, 则

$$\mathbf{X}_2 | \mathbf{X}_1 = \mathbf{x}_1 \sim N(\boldsymbol{\mu}_2 + \Sigma_{21}\Sigma_{11}^{-1}(\mathbf{x}_1 - \boldsymbol{\mu}_1), \Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12}).$$

3.4 多维舍选抽样法

与一维完全平行: 目标联合密度 $p(\mathbf{x})$, 建议联合密度 $f(\mathbf{x})$ (容易抽, 如各分量独立均匀), $M \geq \sup p/f$ 。抽 $\mathbf{y} \sim f, u \sim U(0, 1)$, 若 $u \leq \frac{p(\mathbf{y})}{Mf(\mathbf{y})}$ 接受。常用于在不规则区域 (如圆盘、单纯形) 上抽均匀点: 在包住它的方块里抽均匀点, 落在区域内则接受。

3.5 离散随机向量: 条件分布法与多项分布

例 (放球问题): 把若干球独立等概率放入三个篮子, X 为入 A 篮个数、 Y 为入 B 篮个数, 先抽 $X \sim B(n, 1/3)$, 再抽 $Y | X = x \sim B(n - x, 1/2)$ 。

多项分布 $\text{Mult}(n; p_1, \dots, p_r)$: 盒中 r 种颜色比例 $p_1, \dots, p_r$, 有放回取 n 次, X_i 为第 i 色出现次数。两种生成方式:

1. **逐次分类法:** 做 n 次独立的 r 点离散抽样 (查表法), 统计各类次数;
2. **条件分布法:** $X_1 \sim B(n, p_1); X_2 | X_1 = x_1 \sim B(n - x_1, \frac{p_2}{1 - p_1})$; 一般地

$$X_k | X_1, \dots, X_{k-1} \sim B\left(n - \sum_{i < k} x_i, \frac{p_k}{1 - \sum_{i < k} p_i}\right).$$

3.6 本章考点与题型

高频题型

1. 用变换法生成二维正态：写出 η_1, η_2 的表达式并验证期望、方差、相关系数（如 $\mu_1 = \mu_2 = 0, \sigma_1 = \sigma_2 = 2, \rho = 0.8$ 的数值题）。
2. 条件分布法生成二维正态：写出 $X_2 | X_1$ 的条件正态参数，给出两步算法。
3. 条件分布法生成离散向量：放球/多项分布，写出逐分量的条件二项分布。
4. Jacobi 公式推导：给出变换求新密度（如证明 Box-Muller）。

4 第3章 参数估计的统计计算

4.1 总览

本章用蒙特卡洛 (Monte Carlo, MC) 方法研究估计量本身的统计性质：估计量 $\hat{\theta}(X_1, \dots, X_n)$ 也是随机变量，它的期望、方差、MSE 在理论上往往算不出来，但可以“重复抽样—重复计算估计值—对估计值求样本均值/方差”来数值逼近。

4.2 用 MC 估计估计量的期望与方差

核心算法（必背流程）

1. 从总体 X 中随机生成一组容量为 n 的数据 $X_{11}, \dots, X_{1n}$ ，计算估计值 $\hat{\theta}^{(1)} = \hat{\theta}(X_{11}, \dots, X_{1n})$ ；
2. 独立重复上述步骤 K 次，得 $\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(K)}$ ；
3. 用这 K 个值的样本均值与样本方差估计 $\hat{\theta}$ 的期望与方差：

$$\widehat{\mathbb{E}(\hat{\theta})} = \frac{1}{K} \sum_{k=1}^K \hat{\theta}^{(k)}, \quad \widehat{\text{Var}(\hat{\theta})} = \frac{1}{K} \sum_{k=1}^K \left(\hat{\theta}^{(k)} - \bar{\hat{\theta}} \right)^2.$$

例 1 (验证 $\bar{X}$ 的性质): $X_i \sim N(\mu, \sigma^2)$ ，理论上 $\mathbb{E}\bar{X} = \mu$, $\text{Var}\bar{X} = \sigma^2/n$ 。MC 验证：重复 K 组、每组 n 个正态数，求每组均值，再对 K 个均值求均值/方差，与理论值比较。**精度**： $\widehat{\mathbb{E}(\bar{X})}$ 的误差方差约为 $\sigma^2/(nK)$ ， K 越大越准。

例 2 (截断分布的均值估计)：对截断于 $[0, 1]$ 的分布 $X_{[0,1]}$ ，其均值 θ 的估计 $\hat{\theta} = \frac{1}{n} \sum X_i$ ，理论分布复杂，可用 MC 评估 $\hat{\theta}$ 的偏差与方差。

用 MC 比较估计量优劣：对同一参数的多个估计量（如均值 vs 中位数估计正态 μ ），分别 MC 估计各自的 $\text{MSE} = \text{Bias}^2 + \text{Var}$ ，小者更优。

4.3 置信区间回顾与覆盖率的 MC 估计

4.3.1 单总体正态均值的置信区间

设 $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$, 置信水平 $1 - \alpha$:

- σ^2 已知: 枢轴量 $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$, 区间

$$\left[\bar{X} - u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right].$$

- σ^2 未知: 用样本方差 S^2 替代, 枢轴量 $T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$, 区间

$$\left[\bar{X} - t_{1-\alpha/2}(n-1) \frac{S}{\sqrt{n}}, \bar{X} + t_{1-\alpha/2}(n-1) \frac{S}{\sqrt{n}} \right].$$

- 方差 σ^2 的区间: $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$, 区间 $\left[\frac{(n-1)S^2}{\chi_{1-\alpha/2}^2}, \frac{(n-1)S^2}{\chi_{\alpha/2}^2} \right]$.

4.3.2 总体比例的 (渐近) 置信区间

$X_i \stackrel{iid}{\sim} B(1, p)$, 由中心极限定理 $\bar{X} \sim N(p, \frac{p(1-p)}{n})$, 得

$$\left[\hat{p} - u_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \hat{p} + u_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right], \quad \hat{p} = \bar{X}.$$

4.3.3 两总体的置信区间

两独立正态总体 $N(\mu_1, \sigma_1^2), N(\mu_2, \sigma_2^2)$:

- 均值差 $\mu_1 - \mu_2$ (方差已知): $\bar{X} - \bar{Y} \pm u_{1-\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$.
- 均值差 (方差未知但相等): 合并方差 $S_w^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}$, $\bar{X} - \bar{Y} \pm t_{1-\alpha/2}(n_1+n_2-2) S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$.
- 方差比 σ_1^2/σ_2^2 : 枢轴量 $\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1-1, n_2-1)$.

4.3.4 置信区间覆盖率的 MC 估计

算法: 检验“区间到底有没有 95% 的把握”

1. 给定真参数 θ , 从总体生成一组样本, 按公式算出区间 $[\hat{\theta}_L^{(1)}, \hat{\theta}_U^{(1)}]$;
2. 重复 K 次;
3. 统计覆盖频率 $\widehat{\text{覆盖率}} = \frac{1}{K} \sum_{k=1}^K I(\hat{\theta}_L^{(k)} \leq \theta \leq \hat{\theta}_U^{(k)})$, 与名义水平 $1 - \alpha$ 比较。

若总体并非正态 (稳健性研究) 或样本量小, 覆盖率可能明显偏离 $1 - \alpha$ ——这正是 MC 模拟的价值。

4.4 本章考点与题型

高频题型

1. 叙述 MC 估计估计量期望/方差的算法步骤（三步流程，必背）。
2. 设计 MC 实验比较两个估计量（用 MSE 作标准，写清生成—计算—汇总）。
3. 写出各种置信区间公式并说明枢轴量及其分布（正态均值已知/未知方差、方差、比例、两总体）。
4. 设计 MC 实验估计置信区间的覆盖率，并解释结果含义。
5. 概念题：无偏性、有效性、相合性、MSE 分解 $MSE = \text{Bias}^2 + \text{Var}$ 。

5 第 4 章 假设检验的统计计算

5.1 总览

本章两大主题：

1. 用 MC 模拟估计检验的第一类错误概率 α 与功效 $1 - \beta$ （很多检验的功效没有显式公式）；
2. 一批非参数检验：拟合优度 χ^2 检验、K-S 检验、随机性检验（变号/游程）、两样本检验（Mann-Whitney U、两样本 K-S、游程）、独立性检验（列联表 χ^2 、相关系数检验）。

5.2 MC 估计第一类错误概率与功效

回顾： $\alpha = \mathbb{P}(\text{拒绝 } H_0 \mid H_0 \text{ 真})$ （弃真）， $1 - \beta = \mathbb{P}(\text{拒绝 } H_0 \mid H_1 \text{ 真})$ （功效）。

引例： $X_i \stackrel{iid}{\sim} N(\mu, 1)$ ，检验 $H_0: \mu = 0$ vs $H_1: \mu \neq 0$ ，统计量 $T = \sqrt{n} \bar{X}$ ， H_0 下 $T \sim N(0, 1)$ ，拒绝域 $|T| > u_{1-\alpha/2}$ 。

MC 估计第一类错误率

1. 在 H_0 成立的参数下（如 $\mu = 0$ ）生成一组容量 n 的样本，计算统计量，记录是否落入拒绝域；
2. 重复 K 次；
3. 估计 $\hat{\alpha} = \frac{\text{拒绝次数}}{K}$ ，应接近名义水平 α 。

MC 估计功效

1. 在 H_1 成立的某个具体参数下（如 $\mu = 0.5$ ）生成样本、算统计量、记录是否拒绝；
2. 重复 K 次， $\widehat{1 - \beta} = \frac{\text{拒绝次数}}{K}$ 。

功效是备择参数的函数（功效函数）： μ 离 0 越远、 n 越大，功效越接近 1。 K 越大估计越稳定（如 $K = 1000$ 、 $\alpha = 0.05$ 时 $\hat{\alpha}$ 的标准差约 $\sqrt{0.05 \times 0.95/1000} \approx 0.007$ ）。

5.3 单样本拟合优度检验

5.3.1 χ^2 拟合优度检验 (总体分布的卡方检验)

H_0 : 总体服从某给定分布 F_0 。把取值范围分成 r 个区间, n_i 为落入第 i 区间的观测频数, p_i 为 F_0 下落入第 i 区间的理论概率, 统计量

$$\chi^2 = \sum_{i=1}^r \frac{(n_i - np_i)^2}{np_i} \stackrel{H_0, n \rightarrow \infty}{\sim} \chi^2(r-1-s),$$

其中 s 为用样本估计的未知参数个数。 χ^2 过大则拒绝 H_0 。**注意**: 要求每格期望频数 $np_i \geq 5$ (否则合并区间)。

5.3.2 单样本 K-S 检验

直接比较经验分布函数 $F_n(x) = \frac{1}{n} \# \{i : X_i \leq x\}$ 与假设分布 $F_0(x)$:

$$D_n = \sup_x |F_n(x) - F_0(x)|.$$

D_n 过大拒绝 H_0 。与 χ^2 相比: K-S 不用分组、适合连续分布、对小样本更有效; χ^2 适合离散/分组数据。

5.3.3 随机性检验: 变号检验与游程检验

检验序列是否“随机”(无趋势、无相关):

- **变号 (符号) 检验**: 看相邻观测的差的符号变化次数是否符合随机序列的期望;
- **游程检验**: 把序列按高于/低于中位数化为 0-1 序列, **游程** = 连续相同符号的最大段。设 1 有 m 个、0 有 n 个, 游程总数 R 在随机假设下

$$\mathbb{E}R = \frac{2mn}{m+n} + 1, \quad \text{Var}R = \frac{2mn(2mn - m - n)}{(m+n)^2(m+n-1)},$$

大样本时 $\frac{R - \mathbb{E}R}{\sqrt{\text{Var}R}} \sim N(0, 1)$ 。游程过多或过少都拒绝随机性。

5.4 两样本非参数检验

设两组独立样本 $X_1, \dots, X_m$ 与 $Y_1, \dots, Y_n$, 检验两总体分布是否相同。

5.4.1 Mann-Whitney U 检验 (曼-惠特尼)

把两组混合排序求秩。记 W 为 X 组的秩和 (Wilcoxon 秩和),

$$U = W - \frac{m(m+1)}{2} \quad (\text{即 } X \text{ 超过 } Y \text{ 的对数}).$$

H_0 (同分布) 下

$$\mathbb{E}U = \frac{mn}{2}, \quad \text{Var}U = \frac{mn(m+n+1)}{12},$$

大样本用正态近似 $Z = \frac{U - \mathbb{E}U}{\sqrt{\text{Var}U}} \sim N(0, 1)$ 。适用于检验**位置 (中位数) 差异**, 不要求正态。

5.4.2 两样本 K-S 检验

$$D_{m,n} = \sup_x |F_m(x) - G_n(x)|,$$

两经验分布函数的最大偏差，过大则拒绝”两总体同分布”。对位置、刻度、形状差异都敏感。

5.4.3 两样本游程检验

把混合样本从小到大排序，按来自 X 还是 Y 标记成 0-1 序列数游程 R 。若两总体相同，两种标记充分混杂， R 应较大； R 显著偏小则拒绝。均值方差公式同上节（ m, n 为两组样本量）。

5.5 独立性检验

5.5.1 列联表 χ^2 检验

$r \times c$ 列联表，检验行变量与列变量独立。 n_{ij} 为观测频数，行和 $n_{i\cdot}$ 、列和 $n_{\cdot j}$ ，独立时期望频数 $\hat{e}_{ij} = \frac{n_{i\cdot} n_{\cdot j}}{n}$ ，统计量

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(n_{ij} - \hat{e}_{ij})^2}{\hat{e}_{ij}} \stackrel{H_0}{\sim} \chi^2((r-1)(c-1)).$$

5.5.2 相关系数检验

二维正态样本检验 $H_0: \rho = 0$ 。样本相关系数 r ，统计量

$$T = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \stackrel{H_0}{\sim} t(n-2),$$

$|T|$ 过大拒绝（即认为线性相关显著）。（非正态时可用 Spearman 秩相关检验。）

5.6 本章考点与题型

高频题型

1. **概念题**：两类错误、功效的定义；为什么需要 MC 估计功效。
2. **叙述 MC 估计 α /功效的算法步骤**（注意：估 α 在 H_0 下生成数据，估功效在 H_1 下生成数据——最易混！）。
3. **χ^2 拟合优度计算题**：给频数表算 χ^2 与自由度（记得减去估计参数个数 s ）。
4. **选择合适的非参数检验**：单样本分布拟合用 χ^2 /K-S；两样本位置差异用 U 检验；两样本是否同分布用两样本 K-S/游程；随机性用游程检验；列联表独立性用 $\chi^2((r-1)(c-1))$ 。
5. **U 检验/游程检验的正态近似计算**：代均值方差公式算 Z 并查表下结论。

6 第 5 章 减小方差的计算方法 (方差缩减技术)

6.1 总览与动机

蒙特卡洛估计的精度由 $\text{Var}/\sqrt{n}$ 决定。增大 n 代价高 (精度只按 $1/\sqrt{n}$ 提升), 更聪明的办法是构造方差更小的无偏估计量。本章七件武器: 随机投点法 vs 平均值法、对偶 (对照) 变量法、控制变量法、条件期望法、重要抽样法、分层抽样法、随机数重复使用。贯穿本章的模型问题: 计算积分

$$I = \int_0^1 f(x) dx \quad (0 \leq f(x) \leq 1).$$

6.2 随机投点法与平均值法

随机投点法 (hit-or-miss): 在单位正方形内撒独立均匀点 (ξ_i, η_i) , 统计落在曲线下方的比例:

$$\hat{I}_1 = \frac{1}{n} \sum_{i=1}^n I(\eta_i \leq f(\xi_i)).$$

每个指示变量是 $B(1, I)$, 故 $\mathbb{E}\hat{I}_1 = I$,

$$\text{Var}(\hat{I}_1) = \frac{I(1-I)}{n}.$$

平均值法 (样本均值法): 注意 $I = \mathbb{E}f(U)$, $U \sim U(0, 1)$, 于是

$$\hat{I}_2 = \frac{1}{n} \sum_{i=1}^n f(U_i), \quad \text{Var}(\hat{I}_2) = \frac{1}{n} \left(\int_0^1 f^2 dx - I^2 \right).$$

结论 (必考): 平均值法优于随机投点法

因为 $0 \leq f \leq 1$ 时 $f^2 \leq f$, 故

$$\text{Var}(\hat{I}_2) = \frac{1}{n} \left(\int_0^1 f^2 - I^2 \right) \leq \frac{1}{n} \left(\int_0^1 f - I^2 \right) = \frac{I - I^2}{n} = \text{Var}(\hat{I}_1).$$

两者都是无偏估计, 但平均值法方差更小。直觉: 投点法把信息压缩成 0/1, 丢失了 f 的取值信息。

6.3 对偶变量法 (对照变量法)

原理

若 X, Y 同分布 (都无偏地”代表”目标), 且**负相关**, 则

$$\text{Var}\left(\frac{X+Y}{2}\right) = \frac{1}{4}(\text{Var}X + \text{Var}Y + 2\text{Cov}(X, Y)) < \frac{\text{Var}X}{2} \quad (\text{独立两样本平均的方差}),$$

当 $\text{Cov}(X, Y) < 0$ 时方差被进一步压低。

标准做法: $U \sim U(0, 1)$ 时 $1-U$ 也 $\sim U(0, 1)$, 且与 U 完全负相关。估计 $I = \mathbb{E}f(U)$ 用

$$\hat{I}_a = \frac{1}{2n} \sum_{i=1}^n [f(U_i) + f(1-U_i)].$$

关键条件: 若 f 是单调函数, 则 $f(U)$ 与 $f(1-U)$ 负相关, 方差必降; 且同样用 $2n$ 次函数求值, 只需 n 个随机数。

6.4 控制变量法

要估 $\mu = \mathbb{E}X$ 。找一个与 X 相关、且**期望已知**的变量 Y ($\mathbb{E}Y = \mu_Y$ 已知), 构造

$$\hat{\mu}_c = \frac{1}{n} \sum_{i=1}^n [X_i - c(Y_i - \mu_Y)].$$

显然无偏; 方差

$$\text{Var}(X - cY) = \text{Var}X - 2c\text{Cov}(X, Y) + c^2\text{Var}Y$$

关于 c 求导取最小, 得**最优系数**

$$c^* = \frac{\text{Cov}(X, Y)}{\text{Var}Y}, \quad \text{Var}_{\min} = \text{Var}X (1 - \rho_{XY}^2).$$

$|\rho|$ 越接近 1 缩减越多。实际中 Cov, Var 可由同一批模拟样本估计。

6.5 条件期望法 (Rao-Blackwell 化)

原理: 全期望公式 + 方差分解

$$\mathbb{E}X = \mathbb{E}[\mathbb{E}(X | Y)], \quad \text{Var}X = \mathbb{E}[\text{Var}(X | Y)] + \text{Var}[\mathbb{E}(X | Y)] \geq \text{Var}[\mathbb{E}(X | Y)].$$

故用 $Z = \mathbb{E}(X | Y)$ 代替 X : 期望不变 (仍无偏), 方差不增 (一般严格减小)。

操作: 若条件期望 $\mathbb{E}(X | Y = y) = g(y)$ 可以**解析算出**, 则只需模拟 $Y_1, \dots, Y_n$, 用 $\frac{1}{n} \sum g(Y_i)$ 估计 $\mathbb{E}X$ ——把“能用公式算的部分”用公式算掉, 只把算不了的部分交给模拟。

6.6 重要抽样法 (importance sampling)

原理: 换测度

$$I = \int f(x) dx = \int \frac{f(x)}{g(x)} g(x) dx = \mathbb{E}_g \left[\frac{f(X)}{g(X)} \right],$$

其中 g 是自选的密度 (重要抽样密度), 要求 $f(x) \neq 0$ 处 $g(x) > 0$ 。估计量

$$\hat{I} = \frac{1}{n} \sum_{i=1}^n \frac{f(X_i)}{g(X_i)}, \quad X_i \stackrel{iid}{\sim} g.$$

方差 $\text{Var}_g[f(X)/g(X)]$ 在 $g(x) \propto |f(x)|$ 时最小 (理想情形方差为 0, 但不可实现)。**实用原则:** 让 g 的形状尽量接近 $|f|$, 在 $|f|$ 大 (“重要”) 的区域多放抽样概率。**风险:** 若 g 尾部比 f 轻, 比值 f/g 可能爆炸, 方差反而无穷大。

6.7 分层抽样法

把积分区间分成 k 层 $A_1, \dots, A_t$ (如 $[0, 1]$ 等分), 在第 j 层内独立抽 n_j 个点估层内均值, 再加权合并:

$$\hat{I}_{st} = \sum_j p_j \bar{f}_j, \quad p_j = \mathbb{P}(X \in A_j).$$

方差只含层内方差, 消去了层间方差 (与条件期望法同源: $\text{Var}X = \mathbb{E}\text{Var}(X | \text{层}) + \text{Var}\mathbb{E}(X | \text{层})$, 分层把第二项变成 0), 故不会比简单随机抽样差。层内越均匀 (f 在层内变化小) 效果越好; 按 $n_j \propto p_j \sigma_j$ 分配样本量最优 (Neyman 分配)。

6.8 随机数重复使用 (公共随机数法)

比较两个系统 $\theta_1 = \mathbb{E}X$, $\theta_2 = \mathbb{E}Y$ 的差 $\theta_1 - \theta_2$ 时, 用同一组随机数驱动两套模拟, 使 X_i, Y_i 正相关:

$$\text{Var}(X - Y) = \text{Var}X + \text{Var}Y - 2\text{Cov}(X, Y),$$

$\text{Cov} > 0$ 使差的方差减小。口诀: 估”差”用同一随机数 (正相关), 估”和/均值”用对偶变量 (负相关)。

6.9 本章考点与题型

高频题型

1. 证明平均值法方差 $\leq$ 投点法方差 (利用 $f^2 \leq f$, 必背)。
2. 对偶变量法: 写出估计量, 说明无偏性, 证明单调 f 下方差减小; 给定具体 f (如 e^x) 算方差缩减量。
3. 控制变量法: 推导最优 $c^* = \text{Cov}/\text{Var}$ 与最小方差 $\text{Var}X(1 - \rho^2)$ 。
4. 条件期望法: 用方差分解公式说明为何方差不增。
5. 重要抽样: 写出加权估计量, 说明 g 的选取原则与失败风险。
6. 方法辨析/搭配: 给一个场景判断该用哪种方差缩减技术。

7 第 6 章 重抽样方法 (Bootstrap 与 Jackknife)

7.1 总览

第 3 章评估估计量性质时假定总体分布已知 (能反复从总体抽样)。现实中往往只有一份样本、总体分布 F 未知。Bootstrap (自助法, Efron, 1979) 的核心创意: 用经验分布 F_n (即样本本身) 代替总体 F , 从样本中有放回再抽样, 从而近似估计量 $\hat{\theta}(X_1, \dots, X_n)$ 的分布及其特征 (标准误、偏差、置信区间)。

7.2 从蒙特卡洛到 Bootstrap

对比记忆

若 $F(x; \theta)$ 已知 (参数 MC 法):

1. 从总体 F 中独立生成 n 个数据, 算出 $\hat{\theta}_1$;
2. 重复 m 次得 $\hat{\theta}_1, \dots, \hat{\theta}_m$;
3. 用 $\bar{\theta} = \frac{1}{m} \sum \hat{\theta}_i$ 和样本方差估计 $\mathbb{E}\hat{\theta}$, $\text{Var}\hat{\theta}$ 。

若 F 未知 (Bootstrap): 把”从 F 抽样”替换为”从原样本 $\{X_1, \dots, X_n\}$ 中有放回抽 n 个”:

1. 有放回抽得自助样本 $X_{11}^*, \dots, X_{1n}^*$, 算 $\hat{\theta}_1^*$;
2. 重复 m 次得 $\hat{\theta}_1^*, \dots, \hat{\theta}_m^*$;
3. 用 $\{\hat{\theta}_i^*\}$ 的分布近似 $\hat{\theta}$ 的分布。

7.3 Bootstrap 估计标准误与偏差

标准误的 Bootstrap 估计:

$$\widehat{se}_B = \sqrt{\frac{1}{m-1} \sum_{i=1}^m (\hat{\theta}_i^* - \bar{\theta}^*)^2}, \quad \bar{\theta}^* = \frac{1}{m} \sum_{i=1}^m \hat{\theta}_i^*.$$

偏差的 Bootstrap 估计: 真偏差 $\text{Bias}(\hat{\theta}) = \mathbb{E}\hat{\theta} - \theta$ 。Bootstrap 世界里”真参数”是 $\hat{\theta}$ (由原样本算出), ”估计量”是 $\hat{\theta}^*$, 故

$$\widehat{\text{Bias}}_B = \bar{\theta}^* - \hat{\theta}.$$

偏差修正估计:

$$\tilde{\theta} = \hat{\theta} - \widehat{\text{Bias}}_B = 2\hat{\theta} - \bar{\theta}^*.$$

经典例子: $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ 的真实偏差为 $\mathbb{E}\hat{\sigma}^2 - \sigma^2 = -\sigma^2/n$ (低估)。用 Bootstrap 估计该偏差: 对每个自助样本算 $\hat{\sigma}_i^{2*}$, $\widehat{\text{Bias}} = \bar{\hat{\sigma}}^{2*} - \hat{\sigma}^2$, 应接近 $-\hat{\sigma}^2/n$ 。

7.4 Jackknife (刀切法)

逐个”剔除一个观测”构造 n 个删一样本: $\hat{\theta}_{(i)}$ 为去掉 X_i 后用其余 $n-1$ 个数据算的估计, $\bar{\theta}_{(\cdot)} = \frac{1}{n} \sum_i \hat{\theta}_{(i)}$ 。

$$\widehat{\text{Bias}}_J = (n-1)(\bar{\theta}_{(\cdot)} - \hat{\theta}), \quad \widehat{se}_J = \sqrt{\frac{n-1}{n} \sum_{i=1}^n (\hat{\theta}_{(i)} - \bar{\theta}_{(\cdot)})^2}.$$

特点: 确定性算法 (无需随机抽样)、计算量 n 次; 对光滑统计量 (均值、方差等) 效果好, 对不光滑统计量 (如中位数) 可能失效; 可视为 Bootstrap 的线性近似。

7.5 Bootstrap 置信区间

设自助估计 $\hat{\theta}_1^*, \dots, \hat{\theta}_m^*$, 从小到大排序, $\hat{\theta}_{(\alpha/2)}^*, \hat{\theta}_{(1-\alpha/2)}^*$ 为经验分位数。三种常用区间:

1. **标准正态 (标准误) 法**: 假定 $\hat{\theta}$ 近似正态,

$$[\hat{\theta} - u_{1-\alpha/2} \hat{se}_B, \hat{\theta} + u_{1-\alpha/2} \hat{se}_B].$$

2. **百分位数法**: 直接取自助分布的分位数

$$[\hat{\theta}_{(\alpha/2)}^*, \hat{\theta}_{(1-\alpha/2)}^*].$$

3. **枢轴量 (基本) 法**: 用 $\hat{\theta}^* - \hat{\theta}$ 的分布近似 $\hat{\theta} - \theta$ 的分布, 得

$$[2\hat{\theta} - \hat{\theta}_{(1-\alpha/2)}^*, 2\hat{\theta} - \hat{\theta}_{(\alpha/2)}^*].$$

易混点

百分位法区间和枢轴法区间**端点”翻转”**: 枢轴法用 $2\hat{\theta}$ 减去**反向**分位数。偏态分布下两者差异明显; 正态近似法只在自助分布近似对称正态时合适。

7.6 本章考点与题型

高频题型

1. **叙述 Bootstrap 基本思想**: 经验分布替代总体 + 有放回重抽样 (概念题)。
2. **写出 Bootstrap 估计标准误/偏差的步骤公式**; 给小数据集手算一两步。
3. **偏差修正**: $\tilde{\theta} = 2\hat{\theta} - \bar{\theta}^*$ 的来历。
4. **Jackknife 公式**及与 Bootstrap 的比较 (确定性 vs 随机、 n 次 vs m 次、不光滑统计量失效)。
5. **三种 Bootstrap 置信区间的公式与适用场景辨析**。

8 第 7 章 EM 算法

8.1 总览与动机

极大似然估计要求最大化**观测数据**的对数似然。但当数据**不完整**——存在未观测到的**隐变量**(latent variable) 或缺失数据时, 观测似然中含有”对隐变量求和/积分”的项, 直接最大化非常困难。

EM 算法 (Expectation–Maximization, Dempster–Laird–Rubin, 1977) 的思路: 完整数据的似然容易最大化, 但隐变量不知道——那就用**当前参数估计**下隐变量的条件分布, 先算完整数据对数似然的**条件期望** (E 步), 再对它**最大化** (M 步), 反复迭代直到收敛。

8.2 算法框架（必背）

记观测数据 $X = \{x_1, \dots, x_n\}$ ，隐变量 Y ，完整数据 $Z = (X, Y)$ 。完整数据似然 $L(Z; \theta) = p(X, Y; \theta)$ 。

EM 迭代（第 i 步）

- **E 步**：在当前估计 $\theta^{(i-1)}$ 下计算 Q 函数

$$Q(\theta, \theta^{(i-1)}) = \mathbb{E}[\log L(Z; \theta) | X; \theta^{(i-1)}] = \begin{cases} \int \log p(X, y; \theta) p(y | X; \theta^{(i-1)}) dy, & Y \text{ 连续}, \\ \sum_y \log p(X, y; \theta) p(y | X; \theta^{(i-1)}), & Y \text{ 离散}. \end{cases}$$

即：对完整数据对数似然，关于“隐变量在旧参数下的后验分布”求期望。

- **M 步**：更新参数

$$\theta^{(i)} = \arg \max_{\theta} Q(\theta, \theta^{(i-1)}).$$

- 重复 E、M 两步直至 $\|\theta^{(i)} - \theta^{(i-1)}\|$ 或似然增量小于阈值。

收敛性质

EM 每步迭代使观测似然**单调不减**： $\log p(X; \theta^{(i)}) \geq \log p(X; \theta^{(i-1)})$ （可由 Jensen 不等式证明）。因此算法必收敛到似然的驻点，但**只保证局部极大值，不保证全局最优**；对初值敏感，实际中常取多组初值取最优。

8.3 经典例子一：两硬币问题

A、B 两枚硬币正面概率分别为 p_A, p_B 。做 6 组试验，每组掷 5 次，观测 $X_i = (x_{i1}, \dots, x_{i5})$ ($x_{ij} = 1$ 表正面)；**不知道每组用的是哪枚硬币**（隐变量 $Y_i \in \{A, B\}$ ）。

- 若 Y_i 已知：MLE 平凡——分别统计 A、B 投出的正面频率即可。
- Y_i 未知则用 EM。记第 i 组正面数 h_i （共 5 次）：
- **E 步**：用当前 $(p_A^{(t)}, p_B^{(t)})$ 算每组来自 A 的后验概率（贝叶斯公式）

$$\mu_i = \mathbb{P}(Y_i = A | X_i) = \frac{(p_A^{(t)})^{h_i} (1 - p_A^{(t)})^{5-h_i}}{(p_A^{(t)})^{h_i} (1 - p_A^{(t)})^{5-h_i} + (p_B^{(t)})^{h_i} (1 - p_B^{(t)})^{5-h_i}}.$$

（先验取 1/2。）

- **M 步**：按后验概率“软分配”正面数并重新估频率

$$p_A^{(t+1)} = \frac{\sum_i \mu_i h_i}{\sum_i \mu_i \cdot 5}, \quad p_B^{(t+1)} = \frac{\sum_i (1 - \mu_i) h_i}{\sum_i (1 - \mu_i) \cdot 5}.$$

8.4 经典例子二：多项分布参数的 EM

观测频数服从多项分布、但某些类别的概率由公共参数 θ 通过混合方式表达，且某个观测格子实际上是两个“隐格子”之和（如经典的 197 只动物四类问题：概率 $(\frac{1}{2} + \frac{\theta}{4}, \frac{1-\theta}{4}, \frac{1-\theta}{4}, \frac{\theta}{4})$ ）。做法：把第一格拆成 $\frac{1}{2}$ 与 $\frac{\theta}{4}$ 两个隐格子，E 步算分到隐格子的期望频数，M 步对完整数据多项似然求 θ 的显式 MLE。

8.5 经典例子三：正态分布缺失数据

样本 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ ，部分观测缺失。E 步：缺失值用其条件期望（当前参数下即 $\mu^{(t)}$ ）填补，二阶矩用 $E(X^2) = \mu^{(t)2} + \sigma^{(t)2}$ ；M 步：用“完整化”后的充分统计量更新 μ, σ^2 。（注意：不能简单用 $\mu^{(t)}$ 填值再当真数据算方差，要用二阶矩的条件期望，否则低估方差。）

8.6 经典例子四：混合模型（重点）

一维两分量高斯混合：密度

$$p(x; \theta) = \pi \phi(x; \mu_1, \sigma_1^2) + (1 - \pi) \phi(x; \mu_2, \sigma_2^2),$$

隐变量 $y_i \in \{1, 2\}$ 表示 x_i 来自哪个分量。

高斯混合的 EM（必背）

E 步：计算“责任”（后验分量概率）

$$\gamma_{i1} = \frac{\pi^{(t)} \phi(x_i; \mu_1^{(t)}, \sigma_1^{2(t)})}{\pi^{(t)} \phi(x_i; \mu_1^{(t)}, \sigma_1^{2(t)}) + (1 - \pi^{(t)}) \phi(x_i; \mu_2^{(t)}, \sigma_2^{2(t)})}, \quad \gamma_{i2} = 1 - \gamma_{i1}.$$

M 步：加权更新 ($k = 1, 2$)

$$\pi^{(t+1)} = \frac{1}{n} \sum_i \gamma_{i1}, \quad \mu_k^{(t+1)} = \frac{\sum_i \gamma_{ik} x_i}{\sum_i \gamma_{ik}}, \quad \sigma_k^{2(t+1)} = \frac{\sum_i \gamma_{ik} (x_i - \mu_k^{(t+1)})^2}{\sum_i \gamma_{ik}}.$$

多维高斯混合（GMM）完全类似：均值换成向量加权平均、方差换成加权协方差矩阵 $\Sigma_k = \frac{\sum_i \gamma_{ik} (x_i - \mu_k)(x_i - \mu_k)^T}{\sum_i \gamma_{ik}}$ 。

8.7 本章考点与题型

高频题型

1. **叙述 EM 算法的一般步骤：**写出 Q 函数定义、E 步、M 步、停止准则（必背）。
2. **概念题：**为什么需要 EM（隐变量使观测似然难以直接最大化）；收敛性（似然单调不减、只到局部极值、初值敏感）。
3. **两硬币问题：**写出 E 步后验概率与 M 步更新公式，或代数值迭代一步。
4. **高斯混合 EM：**写出责任 γ_{ik} 与 M 步三组更新公式；解释“软聚类”含义。
5. **多项分布/缺失数据 EM：**按“拆隐格子 → 期望频数 → 显式 MLE”流程推导。

9 模拟试题 (附详细解答)

说明: 覆盖第 1-7 章主要考点, 题型为: 概念简答、算法设计、推导证明、计算题。建议先独立完成再看解答。

一、简答题 (每题 6 分)

1. 叙述逆变换法生成连续型分布随机数的原理与步骤, 并指出其适用前提。
2. 什么是检验的第一类错误、第二类错误与功效? 如何用蒙特卡洛方法估计某检验的功效?
3. 简述 Bootstrap 方法的基本思想, 并说明它与第 3 章“已知总体分布的蒙特卡洛模拟”的区别。
4. 简述 EM 算法的适用场景与 E 步、M 步的含义, 并说明其收敛性质。

二、算法设计题 (每题 10 分)

5. 用逆变换法生成密度为 $f(x) = 3x^2$, $0 < x < 1$ 的随机数, 写出公式与步骤。
6. 设计舍选算法生成 Beta(2, 2) (密度 $p(x) = 6x(1-x)$, $0 < x < 1$) 的随机数: 求最小常数 M 、写出算法、求平均接受概率。
7. 写出生成二维正态 $N_2(\mathbf{0}, \Sigma)$, $\Sigma = \begin{pmatrix} 4 & 3.2 \\ 3.2 & 4 \end{pmatrix}$ (即 $\sigma_1 = \sigma_2 = 2, \rho = 0.8$) 随机向量的变换法步骤。
8. 给出用蒙特卡洛方法估计“ σ 未知时正态均值 t 置信区间覆盖率”的完整算法。

三、推导与计算题 (每题 12 分)

9. 设 $I = \int_0^1 e^x dx$ 。(1) 写出平均值法估计量 $\hat{I}_2$ 并求其方差; (2) 写出对偶变量估计量并说明为何方差更小。
10. 推导控制变量法最优系数 c^* 及最小方差。
11. 数据 1, 3, 5, 统计量为样本均值。(1) 写出 Jackknife 的三个删一均值并计算 $\hat{se}_J$; (2) 叙述 Bootstrap 估计标准误的步骤。
12. 两分量高斯混合模型 $p(x) = \pi\phi(x; \mu_1, 1) + (1-\pi)\phi(x; \mu_2, 1)$ (方差已知为 1)。写出 EM 的 E 步与 M 步公式。

参考解答

1. 原理: 若 F 连续严格单调, $U \sim U(0, 1)$, 则 $F^{-1}(U) \sim F$ 。因为 $\mathbb{P}(F^{-1}(U) \leq x) = \mathbb{P}(U \leq F(x)) = F(x)$ 。步骤: (i) 产生 $u \sim U(0, 1)$; (ii) 输出 $x = F^{-1}(u)$ 。前提: F 的反函数存在且能显式 (或方便数值) 求出。

2. 第一类错误 (弃真): H_0 真却拒绝, 概率 α ; 第二类错误 (取伪): H_0 假却接受, 概率 β ; 功效 $= 1 - \beta = \mathbb{P}(\text{拒绝 } H_0 \mid H_1)$ 。MC 估计功效: 在 H_1 的某个具体参数下生成容量 n 的样本 $\rightarrow$ 计算检验统计量 $\rightarrow$ 记录是否拒绝; 独立重复 K 次, 功效估计为拒绝频率 (拒绝次数 / K)。

3. Bootstrap: 总体分布未知时, 用经验分布 F_n 代替总体 F , 从原样本中有放回抽取容量 n 的自助样本, 重复 m 次, 用自助统计量 $\hat{\theta}_1^*, \dots, \hat{\theta}_m^*$ 的经验分布近似 $\hat{\theta}$ 的抽样分布。区别: 第 3 章每次从已知总体生成新数据; Bootstrap 只用一份样本反复重抽。

4. 适用: 数据含隐变量/缺失数据, 观测似然难以直接最大化。E 步: 在当前参数下求完整数据对数似然关于隐变量后验分布的条件期望 $Q(\theta, \theta^{(i-1)}) = \mathbb{E}[\log L(Z; \theta) \mid X; \theta^{(i-1)}]$; M 步: $\theta^{(i)} = \arg \max_{\theta} Q(\theta, \theta^{(i-1)})$ 。性质: 观测似然单调不减, 必收敛, 但只保证局部极大、对初值敏感。

5. $F(x) = \int_0^x 3t^2 dt = x^3$ 。令 $u = x^3$ 得 $x = u^{1/3}$ 。步骤: 产生 $u \sim U(0, 1)$, 输出 $x = u^{1/3}$ 。

6. 取建议密度 $f(x) = 1$ ($U(0, 1)$)。 $p(x) = 6x(1-x)$ 在 $x = 1/2$ 取最大 $p(1/2) = 3/2$, 故最小 $M = 3/2$, $h(y) = \frac{p(y)}{M} = 4y(1-y)$ 。算法: (i) 产生 $y \sim U(0, 1)$ 、 $u \sim U(0, 1)$; (ii) 若 $u \leq 4y(1-y)$ 输出 $x = y$, 否则返回 (i)。平均接受概率 $= 1/M = 2/3$ 。

7. (i) 用 Box-Muller 等方法生成独立 $\xi_1, \xi_2 \sim N(0, 1)$; (ii) 令

$$\eta_1 = 2\xi_1, \quad \eta_2 = 2(0.8\xi_1 + \sqrt{1-0.64}\xi_2) = 1.6\xi_1 + 1.2\xi_2.$$

验证: $\text{Var}\eta_1 = \text{Var}\eta_2 = 4$, $\text{Cov}(\eta_1, \eta_2) = 2 \times 1.6 = 3.2$, 正确。

8. 给定真参数 μ_0, σ_0 , 置信水平 $1 - \alpha$: (i) 生成 $X_1, \dots, X_n \sim N(\mu_0, \sigma_0^2)$, 算 $\bar{X}, S$, 得区间 $\bar{X} \pm t_{1-\alpha/2}(n-1)S/\sqrt{n}$; (ii) 记录是否覆盖 μ_0 (即 μ_0 是否落入区间); (iii) 独立重复 K 次, 覆盖率估计 = 覆盖次数 / K , 与 $1 - \alpha$ 比较。

9. (1) $\hat{I}_2 = \frac{1}{n} \sum e^{U_i}$, $U_i \sim U(0, 1)$ 。 $\mathbb{E}e^U = e - 1 = I$; $\mathbb{E}e^{2U} = \frac{e^2-1}{2}$, 故

$$\text{Var}(\hat{I}_2) = \frac{1}{n} \left(\frac{e^2-1}{2} - (e-1)^2 \right) \approx \frac{0.2420}{n}.$$

(2) 对偶估计量 $\hat{I}_a = \frac{1}{2n} \sum [e^{U_i} + e^{1-U_i}]$ 。因 e^x 单调增, e^U 与 e^{1-U} 负相关: $\text{Cov}(e^U, e^{1-U}) = \mathbb{E}e^{U+1-U} - (\mathbb{E}e^U)^2 = e - (e-1)^2 \approx -0.2342 < 0$, 故 $\text{Var}(\hat{I}_a) = \frac{1}{2n} [\text{Var}(e^U) + \text{Cov}(e^U, e^{1-U})] \approx \frac{0.0039}{n}$, 方差缩减约 60 倍。

10. $g(c) = \text{Var}(X - cY) = \text{Var}X - 2c\text{Cov}(X, Y) + c^2\text{Var}Y$ 是 c 的开口向上抛物线, $g'(c) = -2\text{Cov}(X, Y) + 2c\text{Var}Y = 0 \Rightarrow c^* = \frac{\text{Cov}(X, Y)}{\text{Var}Y}$ 。代回:

$$g(c^*) = \text{Var}X - \frac{\text{Cov}^2(X, Y)}{\text{Var}Y} = \text{Var}X (1 - \rho_{XY}^2) \leq \text{Var}X.$$

11. (1) 全样本均值 $\hat{\theta} = 3$ 。删一均值: $\hat{\theta}_{(1)} = \frac{3+5}{2} = 4$, $\hat{\theta}_{(2)} = \frac{1+5}{2} = 3$, $\hat{\theta}_{(3)} = \frac{1+3}{2} = 2$; $\bar{\theta}_{(\cdot)} = 3$ 。

$$\hat{s}e_J = \sqrt{\frac{n-1}{n} \sum_i (\hat{\theta}_{(i)} - 3)^2} = \sqrt{\frac{2}{3} \times (1+0+1)} = \sqrt{4/3} \approx 1.155.$$

(与理论 $S/\sqrt{n} = 2/\sqrt{3}$ 一致。) (2) Bootstrap: 从 $\{1, 3, 5\}$ 中有放回抽 3 个得自助样本, 算均值 $\hat{\theta}_i^*$; 重复 m 次; $\hat{s}e_B = \sqrt{\frac{1}{m-1} \sum (\hat{\theta}_i^* - \hat{\theta}^*)^2}$ 。

12. E 步 (责任):

$$\gamma_i = \frac{\pi^{(t)} \phi(x_i; \mu_1^{(t)}, 1)}{\pi^{(t)} \phi(x_i; \mu_1^{(t)}, 1) + (1 - \pi^{(t)}) \phi(x_i; \mu_2^{(t)}, 1)}.$$

M 步:

$$\pi^{(t+1)} = \frac{1}{n} \sum_i \gamma_i, \quad \mu_1^{(t+1)} = \frac{\sum_i \gamma_i x_i}{\sum_i \gamma_i}, \quad \mu_2^{(t+1)} = \frac{\sum_i (1 - \gamma_i) x_i}{\sum_i (1 - \gamma_i)}.$$

临考三句话

一、抽样三板斧: 逆变换 (解 F^{-1})、舍选 (找 $M = \sup p/f$, 接受率 $1/M$)、变换 (Box-Muller、Gamma 链条)。

二、模拟两件事: 估 α 在 H_0 下生成数据, 估功效在 H_1 下生成数据; 估计量性质 = 重复抽样取均值方差。

三、进阶三招: 方差缩减靠”负相关 / 已知信息 / 重要区域”, Bootstrap 靠”样本代总体有放回”, EM 靠”E 求期望、M 求最大、似然单调不减”。