

《统计计算》期末突击复习资料

(第 1-7 章 · 知识点详解 + 考点题型 + 模拟题)

参考课件与高惠璇《统计计算》整理

零基础阅读指南 (先看我!)

这门课到底在学什么? 一句话: 用计算机”做实验”来解决统计问题。传统数理统计靠公式推导, 这门课靠”让计算机模拟成千上万次随机实验, 然后数数/求平均”。整本资料的主线只有一条:

第 1-2 章: 教计算机”掷骰子”(造出服从各种分布的随机数)

第 3-4 章: 用这些”骰子”做实验, 检验统计方法好不好用

第 5 章: 让实验更省钱(同样次数, 误差更小)

第 6 章: 手里只有一份数据、没有总体时怎么办 (Bootstrap)

第 7 章: 数据缺了一块时怎么估参数 (EM 算法)

怎么用这份资料?

- 每章先读开头的”故事”, 知道这章为什么存在;
- 灰色”人话解读”框: 把公式翻译成大白话, 看不懂公式就先看它;
- 蓝框 = 要背的公式定理, 绿框 = 算法步骤, 红框 = 易错点, 橙框 = 例题;
- 时间紧: 直接背每章末尾”考点地图”+ 做完最后的模拟卷。

常用符号速查表。

$U \sim U(0, 1)$	0 到 1 之间的均匀随机数 (计算机的”原料”)
$\mathbb{E}X$	X 的期望 (平均值) $\text{Var}X$: 方差 (波动大小)
$\text{Cov}(X, Y), \rho$	协方差/相关系数 (两个量一起波动的程度)
$F(x) / p(x)$	分布函数 (累积概率) / 密度函数
$X \sim N(\mu, \sigma^2)$	正态分布; Φ 为标准正态分布函数
$\hat{\theta}$	参数 θ 的估计量 (戴帽子 = 用数据算出来的)
$I(\cdot)$	指示函数: 括号里的事发生取 1, 否则取 0
iid	独立同分布 (每个数据独立、来自同一总体)
$u_q, t_q(n)$	标准正态 / t 分布的 q 分位数 (查表得到)

目录

零基础阅读指南	1
1 预备知识：概率论与数理统计基础（讲给你听）	4
1.1 开场白：统计计算到底是一门什么课	4
1.2 随机变量与分布：描述“不确定”的语言	4
1.3 期望、方差与协方差：三个最重要的数字	4
1.4 常用分布速查表	5
1.5 三大抽样分布：统计推断的“工具箱”	5
1.6 大数定律与中心极限定理：蒙特卡洛的两块基石	6
1.7 统计推断速览：估计与检验	6
2 第 1 章 一维（非均匀）随机数的生成	7
2.1 故事的起点：计算机只会一种“骰子”	7
2.2 逆变换法：分布函数是把“魔法尺子”	7
2.3 舍选抽样法：不会算，就用“筛子”筛	8
2.4 变换抽样法：站在已知分布的肩膀上	10
2.5 复合抽样法：先选门，再进门	11
2.6 近似抽样法：中心极限定理客串一把	11
2.7 离散分布抽样：把 $(0, 1)$ 切成一段一段	11
2.8 本章考点地图	12
3 第 2 章 随机向量随机数的抽样方法	12
3.1 故事：从一维到多维，难在“相关”	12
3.2 变换抽样法	13
3.3 条件分布法：链式法则的胜利	14
3.4 多维舍选法	14
3.5 离散随机向量：条件分布法大显身手	15
3.6 本章考点地图	15
4 第 3 章 参数估计的统计计算	16
4.1 故事：估计量自己也是个随机变量	16
4.2 用 MC 估计估计量的期望与方差	16
4.3 置信区间：先复习公式，再用 MC 检验它	17
4.4 用 MC 估计置信区间的覆盖率	18
4.5 本章考点地图	18
5 第 4 章 假设检验的统计计算	19
5.1 故事：检验的“灵敏度”也得靠模拟来量	19
5.2 MC 估计第一类错误概率与功效	19
5.3 单样本检验：数据像不像某个分布？	20
5.3.1 χ^2 拟合优度检验	20

5.3.2	单样本 Kolmogorov–Smirnov (K–S) 检验	21
5.3.3	随机性检验：变号检验与游程检验	21
5.4	两样本检验：两组数据来自同一总体吗？	21
5.4.1	Mann–Whitney U 检验（秩和检验）	21
5.4.2	两样本 K–S 检验与两样本游程检验	22
5.5	独立性检验：两个变量有没有关系？	22
5.5.1	列联表 χ^2 检验	22
5.5.2	相关系数检验	22
5.6	本章考点地图	23
6	第 5 章 方差缩减技术	23
6.1	故事：MC 的”省钱秘籍”	23
6.2	出发点：投点法 vs 平均值法	23
6.3	对偶变量法（antithetic variates）	24
6.4	控制变量法（control variates）	25
6.5	条件期望法（Rao–Blackwell 化）	25
6.6	重要抽样法（importance sampling）	26
6.7	分层抽样法（stratified sampling）	27
6.8	公共随机数法（common random numbers）	27
6.9	本章考点地图	27
7	第 6 章 Bootstrap 与 Jackknife	28
7.1	故事：没有总体，怎么”重复实验”？	28
7.2	Bootstrap 估计标准误与偏差	28
7.3	Jackknife: Bootstrap 的”前辈”	29
7.4	Bootstrap 置信区间：三种造法	30
7.5	本章考点地图	30
8	第 7 章 EM 算法	31
8.1	故事：缺一块拼图的极大似然	31
8.2	一般框架	31
8.3	例一：两枚硬币（隐标签问题）	32
8.4	例二：多项分布的 197 只动物（经典必考）	32
8.5	例三：正态样本含缺失值	33
8.6	例四：高斯混合模型（GMM）	33
8.7	本章考点地图	34
9	模拟试题（附详细解答）	34

1 预备知识：概率论与数理统计基础（讲给你听）

1.1 开场白：统计计算到底是一门什么课

想象你要算一个很复杂的积分、或者想知道某个估计量到底准不准、某个检验到底灵不灵——理论推导推不动了怎么办？统计计算的回答是：**别推了，用计算机”做实验”**！让计算机生成成千上万个随机样本，用样本的频率近似概率、用样本的均值近似期望。这套思想叫**蒙特卡洛方法 (Monte Carlo)**，名字来自摩纳哥的赌城——因为它的本质就是”掷骰子”。

整门课的逻辑链条是：

第 1-2 章：先学会”掷骰子”——怎么生成服从各种分布的随机数（一维和多维）

第 3-4 章：用随机数做统计实验——评估估计量的好坏、检验的功效

第 5 章：实验做得更精——同样的计算量，怎么把误差降到最低（方差缩减）

第 6 章：没有总体也能做实验——只有一份数据时的 Bootstrap 重抽样

第 7 章：似然推不动时的迭代神器——EM 算法

要看懂这一切，先把下面的基础打牢。已经熟悉概率统计的同学可以快速扫一遍，重点看每节末尾的”它和本课的关系”。

1.2 随机变量与分布：描述”不确定”的语言

随机变量 X 是”结果不确定的数”。要完整描述它，用**分布函数 (CDF)**：

$$F(x) = \mathbb{P}(X \leq x),$$

它回答”取值不超过 x 的概率是多少”。 F 单调不减、右连续，从 0 升到 1。

人话解读

把 X 的所有可能取值想成一条数轴上撒的”概率沙子”，总共 1 公斤。 $F(x)$ 就是”从最左边扫到 x 为止，一共扫起了多少沙子”。密度 $f(x)$ 则是” x 这个位置沙子堆得多高”——堆得高的地方，随机数就容易落在那附近。

- 连续型随机变量还有**密度函数 (pdf)** $f(x) = F'(x)$ 。注意密度本身不是概率， $f(x)\Delta x \approx \mathbb{P}(x < X \leq x + \Delta x)$ 才是——密度大的地方，取值”扎堆”。
- 离散型随机变量用**分布律** $p_k = \mathbb{P}(X = x_k)$ ， $\sum_k p_k = 1$ 。

它和本课的关系：第 1 章逆变换法的全部秘密就藏在分布函数 F 里—— F 把任何分布”压平”成 $U(0,1)$ ，反过来 F^{-1} 把均匀分布”拉伸”成任何分布。

1.3 期望、方差与协方差：三个最重要的数字

$$\mathbb{E}(X) = \int x f(x) dx \text{ 或 } \sum_k x_k p_k \quad (\text{平均位置}), \quad \text{Var}(X) = \mathbb{E}(X^2) - (\mathbb{E}X)^2 \quad (\text{波动大小}).$$

协方差 $\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}X\mathbb{E}Y$ 度量两个变量”同涨同跌”的程度，标准化后是相关系数 $\rho \in [-1, 1]$ 。

必须烂熟于心的运算规则：

- $\mathbb{E}(aX + bY) = a\mathbb{E}X + b\mathbb{E}Y$ （永远成立，不需要独立）；
- $\text{Var}(aX + b) = a^2\text{Var}X$ （平移不改变波动，缩放按平方）；
- $\text{Var}(X + Y) = \text{Var}X + \text{Var}Y + 2\text{Cov}(X, Y)$ ；独立时交叉项为 0。

例题 1.1 方差公式热身

设 X, Y 同分布， $\text{Var}X = \sigma^2$ ，相关系数为 ρ 。求 $\text{Var}(\frac{X+Y}{2})$ ，并讨论 $\rho < 0$ 时会发生什么。

【解】

$$\text{Var}\left(\frac{X+Y}{2}\right) = \frac{1}{4}(\text{Var}X + \text{Var}Y + 2\text{Cov}(X, Y)) = \frac{\sigma^2}{2}(1 + \rho).$$

若 X, Y 独立 ($\rho = 0$)，方差为 $\sigma^2/2$ ；若 $\rho < 0$ ，方差比独立时**更小**；极端情形 $\rho = -1$ 时方差为 0！这正是第 5 章对偶变量法的全部原理：故意制造负相关的样本对，平均之后方差骤降。

1.4 常用分布速查表

分布	密度/分布律	期望	方差
均匀 $U(a, b)$	$f = \frac{1}{b-a}, a < x < b$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
指数 $\text{Exp}(\lambda)$	$f = \lambda e^{-\lambda x}, x > 0$	$1/\lambda$	$1/\lambda^2$
正态 $N(\mu, \sigma^2)$	$f = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	μ	σ^2
Gamma(α, γ)	$f = \frac{\gamma^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\gamma x}, x > 0$	α/γ	α/γ^2
Beta(α, β)	$f = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}, 0 < x < 1$	$\frac{\alpha}{\alpha+\beta}$	$\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$
二项 $B(n, p)$	$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$	np	$np(1-p)$
泊松 $P(\lambda)$	$\mathbb{P}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$	λ	λ
几何 $\text{Geo}(p)$	$\mathbb{P}(X = k) = (1-p)^{k-1} p$	$1/p$	$\frac{1-p}{p^2}$

分布之间的”亲戚关系”（第 1 章变换法靠它们吃饭）：

- $\text{Exp}(\lambda) = \text{Gamma}(1, \lambda)$ ；独立 $\text{Gamma}(\alpha_i, \gamma)$ 之和 $\sim \text{Gamma}(\sum \alpha_i, \gamma)$ （可加性）；
- $\chi^2(n) = \text{Gamma}(n/2, 1/2)$ ； $Z_i \stackrel{iid}{\sim} N(0, 1) \Rightarrow \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$ ；
- 尺度变换： $\xi \sim \text{Gamma}(\alpha, \gamma) \Rightarrow \xi/a \sim \text{Gamma}(\alpha, a\gamma)$ ；
- $Z \sim N(0, 1) \Rightarrow \mu + \sigma Z \sim N(\mu, \sigma^2)$ 。

1.5 三大抽样分布：统计推断的”工具箱”

设 $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$ ，样本均值 $\bar{X} = \frac{1}{n} \sum X_i$ ，样本方差 $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ 。则

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1), \quad \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1),$$

且 $\bar{X}$ 与 S^2 独立。两个独立卡方比出 F 分布： $\frac{\chi^2(m)/m}{\chi^2(n)/n} \sim F(m, n)$ 。

记忆口诀：均值正态、方差卡方、标准化用 t 、比方差用 F 。第 3 章构造置信区间时全靠它们。

1.6 大数定律与中心极限定理：蒙特卡洛的两块基石

为什么“用样本均值估期望”是靠谱的？

设 $X_1, X_2, \dots$ 独立同分布， $\mathbb{E}X_i = \mu$ ， $\text{Var}X_i = \sigma^2 < \infty$ 。

- **大数定律 (LLN)**: $\bar{X}_n \xrightarrow{P} \mu$ 。样本够多时样本均值必然贴近真值——保证蒙特卡洛估计方向正确（相合）。
- **中心极限定理 (CLT)**: $\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1)$ 。误差近似正态、量级 $O(1/\sqrt{n})$ ——告诉我们蒙特卡洛估计误差有多大，还顺手给出置信区间。

关键数字感：误差标准差 $= \sigma/\sqrt{n}$ 。想把精度提高 10 倍？样本量得乘 100！所以“砸样本量”很贵，“降 σ ”才是聪明的办法——这就是第 5 章方差缩减的全部动机。

例题 1.2 蒙特卡洛误差估算

用 $n = 10000$ 个 $U(0, 1)$ 随机数以平均值法估计 $I = \int_0^1 e^x dx$ ，已知 $\text{Var}(e^U) \approx 0.242$ 。估计误差的标准差是多少？若要把误差缩小到原来的 $1/10$ ，需要多少样本？

【解】 误差标准差 $\approx \sqrt{0.242/10000} \approx 0.0049$ 。要缩小到 $1/10$ ，由 $1/\sqrt{n}$ 规律，样本量需扩大 100 倍，即 $n = 10^6$ 。这说明蒙特卡洛“加样本”提高精度的效率很低，方差缩减技术非常必要。

1.7 统计推断速览：估计与检验

点估计：用统计量 $\hat{\theta}(X_1, \dots, X_n)$ 猜未知参数 θ 。构造方法：矩估计（用样本矩对上总体矩）、极大似然估计 MLE（找让数据“最可能出现”的参数）。评价一个估计好不好，看三件事：

- **无偏性**： $\mathbb{E}\hat{\theta} = \theta$ ，平均来说不偏不倚；偏差 $\text{Bias} = \mathbb{E}\hat{\theta} - \theta$ ；
- **有效性**：都无偏时，方差小者胜；
- **相合性**：样本越多越接近真值。

综合裁判是均方误差：

$$\text{MSE}(\hat{\theta}) = \mathbb{E}(\hat{\theta} - \theta)^2 = \text{Bias}^2 + \text{Var}(\hat{\theta}) \quad (\text{“准不准”} + \text{“稳不稳”}).$$

人话解读

打靶类比：偏差 Bias 是“瞄准点偏离靶心多远”（系统性偏差），方差 Var 是“弹着点散布多大”（手抖程度）。MSE 把两者合成一个总分：又瞄得正、又打得稳，才是好估计。

置信区间：给出一个随机区间，让它以 $1 - \alpha$ 的概率罩住真参数。套路是找枢轴量——一个含 θ 但分布完全已知的量（如 $\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$ ），对它的分位数解不等式即得区间。

假设检验：法庭审判的逻辑—— H_0 是“被告无罪”，证据（数据）足够反常才定罪（拒绝 H_0 ）。两种错误：

	H_0 实际为真	H_0 实际为假
拒绝 H_0	第一类错误（弃真） ，概率 α	正确！ 概率 = $1 - \beta$ = 功效
接受 H_0	正确	第二类错误（取伪） ，概率 β

α 是我们主动控制的（显著性水平），功效 $1 - \beta$ 衡量检验“抓坏人”的本事。很多检验的功效根本算不出解析式——第 4 章就教你用模拟去“量”它。

似然函数：观测到 $x_1, \dots, x_n$ 后， $L(\theta) = \prod_i f(x_i; \theta)$ 把“参数取 θ 时看到这批数据的可能性”写成 θ 的函数，MLE 就是它的最大值点。第 7 章 EM 算法处理的就是“数据缺一块、似然写不全”时怎么仍然做 MLE。

2 第 1 章 一维（非均匀）随机数的生成

2.1 故事的起点：计算机只会一种“骰子”

计算机靠线性同余等确定性算法产生**伪随机数**，它们看起来就像 $U(0, 1)$ 均匀分布的独立样本。这是我们手里**唯一**的原材料。可现实世界的随机现象千姿百态：排队等待时间像指数分布、测量误差像正态分布、比例数据像 Beta 分布……

于是第 1 章的任务就一句话：**把均匀随机数这块“面团”，揉成任何想要的分布**。本章给出五种“揉面手法”：逆变换法、舍选法、变换法、复合法、近似法，最后处理离散分布。

定义 2.1 (随机数). 设 X 有分布函数 $F(x)$ ，从 F 中随机抽样得到的序列 $\{x_i\}$ 称为该分布的随机数序列， x_i 称为分布 $F(x)$ 的随机数。

2.2 逆变换法：分布函数是把“魔法尺子”

直觉先行。分布函数 F 有个神奇性质：不管 X 是什么分布， $F(X)$ 都被“压平”成 $U(0, 1)$ 。为什么？因为 F 恰好把“概率堆得密”的区域拉宽、把“概率稀”的区域压窄，压完之后处处均匀。既然 F 能压平，那 F^{-1} 就能反向操作：**把均匀随机数拉伸回目标分布**。这就是逆变换法。

定理 1.1.1 (逆变换法原理，证明必考)

设连续型随机变量 η 的分布函数 $F(x)$ 连续且严格单调上升，反函数 F^{-1} 存在。则

1. $F(\eta) \sim U(0, 1)$;

2. 若 $U \sim U(0, 1)$ ，则 $F^{-1}(U)$ 的分布函数恰为 $F(x)$ 。

人话解读

不用被定理吓到，它只说了两件事：(1) 把任何随机数塞进它自己的分布函数里，出来的是 0 到 1 的均匀数；(2) 反过来，把均匀数塞进反函数 F^{-1} ，出来的就是目标分布的随机数。考试用法永远是三步：密度积分得 $F \rightarrow$ 解方程 $u = F(x)$ 把 x 解出来 $\rightarrow$ 写“产生 u ，输出 $x = \dots$ ”。

证明. (1) 记 $G(u) = \mathbb{P}(F(\eta) \leq u)$ 。当 $u \in [0, 1]$ 时，由 F 严格单调，

$$G(u) = \mathbb{P}\{\eta \leq F^{-1}(u)\} = F(F^{-1}(u)) = u;$$

$u < 0$ 时 $G(u) = 0$; $u > 1$ 时 $G(u) = 1$ 。这正是 $U(0, 1)$ 的分布函数。

(2) $\mathbb{P}(F^{-1}(U) \leq x) = \mathbb{P}(U \leq F(x)) = F(x)$ (均匀分布落在 $[0, F(x)]$ 的概率就是其长度)。□

算法步骤

1. 产生 $u \sim U(0, 1)$;
2. 计算 $x = F^{-1}(u)$, 输出 x 。

使用前提: F^{-1} 能显式(或方便地数值)求出。

例题 2.1 指数分布(最经典)

用逆变换法生成 $\text{Exp}(\lambda)$ (密度 $f(x) = \lambda e^{-\lambda x}, x > 0$) 的随机数。

【解】先求分布函数: $F(x) = \int_0^x \lambda e^{-\lambda t} dt = 1 - e^{-\lambda x}$ 。令 $u = 1 - e^{-\lambda x}$, 解出

$$x = -\frac{1}{\lambda} \ln(1 - u).$$

又因为 $U \sim U(0, 1)$ 时 $1 - U$ 也 $\sim U(0, 1)$, 可简化为 $x = -\frac{1}{\lambda} \ln u$ 。步骤: 产生 $u \sim U(0, 1)$, 输出 $x = -\frac{1}{\lambda} \ln u$ 。

例题 2.2 给密度求抽样公式

密度为 $f(x) = 3x^2, 0 < x < 1$, 写出逆变换抽样公式。

【解】 $F(x) = \int_0^x 3t^2 dt = x^3$ 。令 $u = x^3$ 得 $x = u^{1/3}$ 。故产生 $u \sim U(0, 1)$, 输出 $x = u^{1/3}$ 即可。套路总结: 密度 $\rightarrow$ 积分得 $F \rightarrow$ 解方程 $u = F(x)$ 得 $x = F^{-1}(u)$ 。

例题 2.3 柯西分布与威布尔分布

写出柯西分布 ($F(x) = \frac{1}{2} + \frac{1}{\pi} \arctan x$) 与威布尔分布 ($F(x) = 1 - e^{-(x/\beta)^\alpha}$) 的逆变换公式。

【解】柯西: $u = \frac{1}{2} + \frac{1}{\pi} \arctan x \Rightarrow x = \tan(\pi(u - \frac{1}{2}))$ 。

威布尔: $u = 1 - e^{-(x/\beta)^\alpha} \Rightarrow x = \beta(-\ln(1 - u))^{1/\alpha}$ (同样可把 $1 - u$ 换成 u)。

逆变换法的“天花板”

正态、Gamma、Beta 等分布的 F 没有初等表达式, F^{-1} 解不出来, 逆变换法就卡住了。怎么办? 请看下一节——不会算反函数, 那就“撒点 + 筛选”。

2.3 舍选抽样法: 不会算, 就用“筛子”筛

直觉先行。想从复杂密度 $p(x)$ 抽样, 但 p 不好直接抽。换个思路: 找一个容易抽的密度 $f(x)$ (比如均匀、指数), 把它“放大” M 倍罩住 p : $p(x) \leq Mf(x)$ 。然后在 Mf 的“大帐篷”下面均匀撒点, 只保留落在 p 曲线下方的点——筛剩下的点, 横坐标恰好按 p 分布! 直观上: p 高的地方留下的点多, p 低的地方留下的点少, 比例刚刚好。

舍选算法(接受—拒绝法)

记 $h(x) = \frac{p(x)}{Mf(x)} \in [0, 1]$ (接受概率函数)。

1. 由建议密度 $f(x)$ 产生 y ;
2. 产生 $u \sim U(0, 1)$ (与 y 独立);
3. 若 $u \leq h(y)$, **接受** $x = y$; 否则**舍弃**, 返回第 1 步。

效率: 每次试验被接受的概率为 $1/M$, 平均 M 次试验出一个样本。所以 M 要尽量小, 最优取 $M = \sup_x p(x)/f(x)$ (通常求寻找最大值)。

人话解读

把目标密度 p 想成一座山, 把 Mf 想成罩在山上的一顶“帐篷”(必须完全罩住, 不能露出山头)。在帐篷下随机撒雨点: 落在山体里的留下, 落在山体和帐篷之间的扔掉。留下的点的横坐标自动服从 p : 山高的地方留点多、山矮的地方留点少。帐篷贴得越紧 (M 越小), 白扔的点越少, 效率越高。算法里的 $u \leq h(y)$ 就是在问: “这滴雨落在山体里了吗?”

例题 2.4 Beta 分布的舍选法

设计算法生成 $\text{Beta}(2, 2)$, 密度 $p(x) = 6x(1-x)$, $0 < x < 1$ 。求最小的 M 与平均接受概率。

【解】 取建议密度 $f(x) = 1$ (即 $U(0, 1)$)。求 p 的最大值: $p'(x) = 6(1-2x) = 0 \Rightarrow x = \frac{1}{2}$, $p(\frac{1}{2}) = \frac{3}{2}$ 。故最小 $M = \frac{3}{2}$, $h(y) = \frac{p(y)}{M} = 4y(1-y)$ 。

算法: (i) 产生 $y, u \sim U(0, 1)$; (ii) 若 $u \leq 4y(1-y)$ 输出 $x = y$, 否则回 (i)。

平均接受概率 $= 1/M = 2/3$, 即平均 1.5 次试验得到一个样本。

一般 $\text{Beta}(\alpha, \beta)$ ($\alpha, \beta > 1$): 密度最大值在众数 $x_0 = \frac{\alpha-1}{\alpha+\beta-2}$ 处, 取 $M = p(x_0)$ 即可, 套路完全相同。

例题 2.5 半正态法生成标准正态(重点)

用舍选法生成 $N(0, 1)$ 随机数: 先对 $|Z|$ 的密度 $p(x) = \sqrt{\frac{2}{\pi}} e^{-x^2/2}$ ($x > 0$) 抽样, 建议密度取 $\text{Exp}(1)$: $f(x) = e^{-x}$ 。

【解】 求 M :

$$\frac{p(x)}{f(x)} = \sqrt{\frac{2}{\pi}} e^{x-x^2/2}.$$

指数部分 $x - x^2/2$ 在 $x = 1$ 处最大 (导数 $1 - x = 0$), 最大值 $\frac{1}{2}$, 故

$$M = \sqrt{\frac{2}{\pi}} e^{1/2} = \sqrt{\frac{2e}{\pi}} \approx 1.32, \quad h(x) = \frac{p(x)}{Mf(x)} = e^{-(x-1)^2/2}.$$

算法: (i) 产生指数随机数 $y = -\ln u_1$; (ii) 产生 u_2 , 若 $u_2 \leq e^{-(y-1)^2/2}$ 接受; (iii) 再产生 u_3 , 若 $u_3 \leq \frac{1}{2}$ 输出 $-y$, 否则输出 y (随机赋符号, 由对称性得完整正态)。接受率 $1/1.32 \approx 76\%$, 效率很高。

例题 2.6 Gamma 分布的舍选法

生成 $\text{Gamma}(\alpha, 1)$ ($\alpha > 1$)，建议分布取均值匹配的指数分布 $f(x) = \frac{1}{\alpha}e^{-x/\alpha}$ 。说明思路，并说明如何得到一般的 $\text{Gamma}(\alpha, \gamma)$ 。

【解】 计算比值 $\frac{p(x)}{f(x)} = \frac{\alpha}{\Gamma(\alpha)}x^{\alpha-1}e^{-x(1-1/\alpha)}$ 。对 $\ln$ 求导： $\frac{\alpha-1}{x} - (1 - \frac{1}{\alpha}) = 0$ ，解得最大值点 $x^* = \frac{\alpha-1}{1-1/\alpha} = \alpha$ ，代入得 $M = \frac{p(\alpha)}{f(\alpha)} = \frac{\alpha^\alpha e^{-(\alpha-1)}}{\Gamma(\alpha)}$ ，然后按标准舍选流程执行。

得到 $\eta \sim \text{Gamma}(\alpha, 1)$ 后，由尺度性质 $\eta/\gamma \sim \text{Gamma}(\alpha, \gamma)$ 完成一般情形。**注意：**此法要求 $\alpha > 1$ ； $0 < \alpha < 1$ 时需要另选建议分布。

舍选法三大易错点

- M 必须 $\geq \sup p/f$ ，否则“帐篷”罩不住目标密度，结果分布是错的；
- 建议密度的支撑必须覆盖目标密度的支撑（ $p > 0$ 处必须 $f > 0$ ）；
- 无界区间上不能用“均匀建议分布”（常数在 $(-\infty, \infty)$ 积分发散），指数/正态等支撑无界的分布要用指数等做建议分布。

2.4 变换抽样法：站在已知分布的肩膀上

直觉先行。 如果 $\eta = g(\xi)$ ，而 ξ 我们已经会抽，那把 ξ 的样本代入 g 就得到 η 的样本——零成本！所以要熟记分布之间的“亲戚关系”（见预备知识），抽样时沿着关系链“借力”。

必背的变换公式

- **Box-Muller 法：** $U_1, U_2 \stackrel{iid}{\sim} U(0, 1)$ ，则

$$Z_1 = \sqrt{-2 \ln U_1} \cos(2\pi U_2), \quad Z_2 = \sqrt{-2 \ln U_1} \sin(2\pi U_2)$$

是**独立的** $N(0, 1)$ 随机数对（极坐标变换 + Jacobi 可证）。再做 $X = \mu + \sigma Z$ 得任意正态。记忆： $\sqrt{-2 \ln U_1}$ 是“离原点多远”（半径）， $2\pi U_2$ 是“朝哪个方向”（角度），随机半径配随机角度，打出去就是二维正态的一个点，横纵坐标各是一个独立标准正态。

- **卡方：** $Z_1, \dots, Z_n \stackrel{iid}{\sim} N(0, 1) \Rightarrow \sum Z_i^2 \sim \chi^2(n)$ 。
- **Gamma 尺度：** $\xi \sim \text{Gamma}(\alpha, \gamma) \Rightarrow \xi/a \sim \text{Gamma}(\alpha, a\gamma)$ 。
- **对数正态：** $e^{N(\mu, \sigma^2)} \sim \text{LogNormal}$ ； **t 分布：** $\frac{N(0, 1)}{\sqrt{\chi^2(n)/n}}$ ； **F 分布：** $\frac{\chi^2(m)/m}{\chi^2(n)/n}$ 。

例题 2.7 用变换法生成 $\text{Gamma}(1/2, 3)$ （课件原题）

只用标准正态随机数，生成 $\text{Gamma}(1/2, 3)$ 的随机数。

【解】 搭“关系链”：(i) 取 $Z \sim N(0, 1)$ ；(ii) 则 $Z^2 \sim \chi^2(1) = \text{Gamma}(1/2, 1/2)$ ；(iii) 由尺度性质， $\eta = Z^2/6 \sim \text{Gamma}(1/2, 6 \times \frac{1}{2}) = \text{Gamma}(1/2, 3)$ 。

步骤：用 Box-Muller 产生 z ，输出 $\eta = z^2/6$ 。

例题 2.8 生成卡方随机数

写出生成 $\chi^2(n)$ 随机数的变换法步骤, 并说明原理。

【解】 步骤: (i) 用 Box-Muller 生成 n 个独立 $N(0, 1)$ 随机数 $z_1, \dots, z_n$; (ii) 输出 $x = \sum_{i=1}^n z_i^2$ 。

原理: 单个 $z_i^2 \sim \text{Gamma}(1/2, 1/2)$; 由 Gamma 可加性, n 个独立相加 $\sim \text{Gamma}(n/2, 1/2) = \chi^2(n)$ 。

2.5 复合抽样法: 先选门, 再进门

直觉先行。有些密度天生是“混合体”:

$$p(x) = \sum_{i=1}^k w_i p_i(x), \quad w_i > 0, \sum w_i = 1.$$

比如“70% 顾客来自分布 A、30% 来自分布 B”。抽样办法极自然——先按权重掷骰子决定来自哪个成分, 再从那个成分里抽。

算法步骤

1. 产生 $u \sim U(0, 1)$, 按累积权重确定分支 i (离散抽样);

2. 从 $p_i(x)$ 中抽一个数输出。

连续混合 $p(x) = \int p(x|y)g(y)dy$ 同理: 先抽 $y \sim g$, 再抽 $x \sim p(\cdot|y)$ 。

例题 2.9 复合法抽样

$p(x) = \frac{1}{3} \cdot 2x + \frac{2}{3} \cdot 3x^2$, $0 < x < 1$ 。给出复合法抽样方案。

【解】 这是 $w_1 = \frac{1}{3}$, $p_1(x) = 2x$ (即 $F_1 = x^2$, 逆变换 $x = \sqrt{u}$) 与 $w_2 = \frac{2}{3}$, $p_2(x) = 3x^2$ (逆变换 $x = u^{1/3}$) 的混合。**步骤:** (i) 产生 u_1 , 若 $u_1 \leq \frac{1}{3}$ 选成分 1, 否则选成分 2; (ii) 产生 u_2 ; 成分 1 输出 $\sqrt{u_2}$, 成分 2 输出 $u_2^{1/3}$ 。

2.6 近似抽样法: 中心极限定理客串一把

懒人版正态发生器: 取 12 个均匀数相加减 6,

$$Z = \sum_{i=1}^{12} U_i - 6 \approx N(0, 1).$$

道理: $\mathbb{E}U_i = \frac{1}{2}$, $\text{Var}U_i = \frac{1}{12}$, 12 个相加后期望 6、方差 1, 由 CLT 近似正态。优点是简单, 缺点是只取值于 $[-6, 6]$ 、尾部精度差, 正式场合用 Box-Muller 或舍选法。

2.7 离散分布抽样: 把 $(0, 1)$ 切成一段一段

直觉先行。离散分布 $\mathbb{P}(X = x_k) = p_k$ 就像把单位区间切成长度为 $p_1, p_2, \dots$ 的小段: 均匀数 u 掉进第 k 段, 就输出 x_k 。掉进第 k 段的概率恰好是 p_k ——完事!

离散逆变换法（查表法）

累积概率 $q_k = p_1 + \cdots + p_k$ 。产生 $u \sim U(0, 1)$ ，找使 $q_{k-1} < u \leq q_k$ 的 k ，输出 x_k 。正确性： $\mathbb{P}(\text{输出 } x_k) = q_k - q_{k-1} = p_k$ 。

例题 2.10 查表法实战

X 取值 1, 2, 3，概率分别为 0.2, 0.5, 0.3。写出抽样规则，并判断 $u = 0.66$ 输出什么。

【解】 累积概率 $q_1 = 0.2$, $q_2 = 0.7$, $q_3 = 1$ 。规则： $u \leq 0.2$ 输出 1； $0.2 < u \leq 0.7$ 输出 2； $u > 0.7$ 输出 3。 $u = 0.66 \in (0.2, 0.7]$ ，输出 2。

常见离散分布的快捷方法：

- **两点分布** $B(1, p)$ ： $u \leq p$ 输出 1，否则 0；
- **二项分布** $B(n, p)$ ： n 个两点分布相加；
- **几何分布**： $X = \lceil \frac{\ln u}{\ln(1-p)} \rceil$ （“指数分布”取整）；
- **泊松分布** $P(\lambda)$ ：连乘均匀数直到 $\prod_{i=1}^{n+1} u_i < e^{-\lambda}$ ，输出 n （原理：泊松计数 = 单位时间内指数间隔事件的个数）。

2.8 本章考点地图**高频题型清单**

1. **证明逆变换法定理**（送分题，背证明）；
2. **给密度 $\rightarrow$ 求 $F \rightarrow$ 求 $F^{-1} \rightarrow$ 写步骤**（指数、柯西、威布尔、多项式密度）；
3. **设计舍选算法**：求最优 $M = \sup p/f$ （求导）、写算法、答“接受概率 = $1/M$ ”（Beta、半正态、Gamma）；
4. **变换法**：Box-Muller 公式默写；Gamma 链条（正态 $\rightarrow \chi^2 \rightarrow$ Gamma 尺度变换）；
5. **离散查表法**：写规则 + 验证正确性。

3 第2章 随机向量随机数的抽样方法**3.1 故事：从一维到多维，难在“相关”**

第1章我们学会了造一维随机数。多维呢？如果各分量**独立**，那太简单了——每个分量单独抽就行。真正的麻烦在于分量之间**有相关性**：比如身高和体重是正相关的，不能各抽各的。本章三种思路对付相关性：

- **变换法**：从独立分量出发，做一个线性（或非线性）变换“注入”相关性；
- **条件分布法**：一个一个分量地抽，后抽的“看着”先抽的来（链式法则）；
- **舍选法**：一维舍选的多维翻版。

3.2 变换抽样法

基础铺垫：多维密度变换公式。 设 p 维随机向量 $\boldsymbol{\xi}$ 有密度 $f(x_1, \dots, x_p)$ ，作可逆变换 $\boldsymbol{\eta} = g(\boldsymbol{\xi})$ ，则 $\boldsymbol{\eta}$ 的密度为

$$p(\mathbf{y}) = f(g^{-1}(\mathbf{y})) \cdot |J|, \quad J = \det \left(\frac{\partial x_i}{\partial y_j} \right),$$

即“原密度 $\times$ 逆变换 Jacobi 行列式的绝对值”。直觉：变换会拉伸/压缩空间， $|J|$ 是体积缩放因子，密度要按它折算才能保证总概率为 1。（一维的 $p_Y(y) = p_X(x) \left| \frac{dx}{dy} \right|$ 就是它的特例；Box-Muller 的正确性也由它证明。）

主角：多维正态。 多维正态 $N_p(\boldsymbol{\mu}, \Sigma)$ 是统计中最重要的多维分布，它有个极好的性质：**独立标准正态的线性变换仍是正态**，且均值协方差变换规律简单：

$$\mathbf{X} = \boldsymbol{\mu} + L\mathbf{Z} \implies \mathbf{X} \sim N_p(\boldsymbol{\mu}, LL^T).$$

所以只要把 Σ 分解成 LL^T (**Cholesky 分解**， L 为下三角矩阵)，再抽独立标准正态向量 $\mathbf{Z}$ ，线性组合一下就完工。

人话解读

类比一维：一维里我们用 $X = \mu + \sigma Z$ 把标准正态“平移 + 拉伸”成任意正态；多维里 L 就是 σ 的矩阵版——Cholesky 分解 $\Sigma = LL^T$ 相当于给协方差矩阵“开平方”。二维考试只需要背一个结果： $\eta_2 = \mu_2 + \sigma_2(\rho\xi_1 + \sqrt{1-\rho^2}\xi_2)$ 。看结构： ρ 那份是“拄着 ξ_1 的部分”（制造相关）， $\sqrt{1-\rho^2}$ 那份是自己的“新鲜随机性”，两者平方和为 1，保证总方差不变。

生成 $N_p(\boldsymbol{\mu}, \Sigma)$ 的变换法

1. 对 Σ 做 Cholesky 分解 $\Sigma = LL^T$;
2. 用 Box-Muller 生成独立 $Z_1, \dots, Z_p \sim N(0, 1)$;
3. 输出 $\mathbf{X} = \boldsymbol{\mu} + L\mathbf{Z}$ 。

正确性： $\text{Cov}(\mathbf{X}) = L \text{Cov}(\mathbf{Z}) L^T = LIL^T = \Sigma$ 。

例题 3.1 二维正态的变换法（课件原题）

生成 $N_2(\boldsymbol{\mu}, \Sigma)$ ，其中 $\mu_1 = \mu_2 = 0$ ， $\sigma_1 = \sigma_2 = 2$ ， $\rho = 0.8$ 。写出变换公式并验证。

【解】 二维情形的“手工 Cholesky”是必背公式：取独立 $\xi_1, \xi_2 \sim N(0, 1)$ ，令

$$\eta_1 = \mu_1 + \sigma_1 \xi_1, \quad \eta_2 = \mu_2 + \sigma_2(\rho \xi_1 + \sqrt{1-\rho^2} \xi_2).$$

代入数值：

$$\eta_1 = 2\xi_1, \quad \eta_2 = 2(0.8\xi_1 + \sqrt{1-0.64}\xi_2) = 1.6\xi_1 + 1.2\xi_2.$$

验证： $\text{Var}\eta_1 = 4$ ； $\text{Var}\eta_2 = 1.6^2 + 1.2^2 = 2.56 + 1.44 = 4$ ； $\text{Cov}(\eta_1, \eta_2) = 2 \times 1.6 \text{Var}\xi_1 = 3.2 = \sigma_1\sigma_2\rho = 2 \cdot 2 \cdot 0.8$ 。均值、方差、相关系数全部正确，且正态线性组合仍正态，故 $(\eta_1, \eta_2) \sim N_2(\boldsymbol{\mu}, \Sigma)$ 。

3.3 条件分布法：链式法则的胜利

直觉先行。联合密度永远可以“剥洋葱”：

$$f(x_1, x_2, \dots, x_p) = f_1(x_1) \cdot f_2(x_2 | x_1) \cdots f_p(x_p | x_1, \dots, x_{p-1}).$$

所以抽一个 p 维向量 = 抽 p 次一维：先抽 x_1 ，然后“在 x_1 已知的世界里”抽 x_2 ，依此类推。相关性自动被条件分布编码进去了。

算法步骤

1. 从边际 $f_1(x_1)$ 抽 x_1 ；
2. 从条件密度 $f_2(x_2 | x_1)$ 抽 x_2 ；
3. ...直到 $f_p(x_p | x_1, \dots, x_{p-1})$ 抽出 x_p ，输出整个向量。

多维正态的条件分布公式（需记）。把 $\mathbf{X}, \boldsymbol{\mu}, \Sigma$ 分块： $\mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{pmatrix}$ ， $\Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$ ，则

$$\mathbf{X}_2 | \mathbf{X}_1 = \mathbf{x}_1 \sim N(\boldsymbol{\mu}_2 + \Sigma_{21}\Sigma_{11}^{-1}(\mathbf{x}_1 - \boldsymbol{\mu}_1), \Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12}).$$

人话解读

用“身高体重”记二维版：已知一个人身高 x_1 ，猜他体重。猜测中心不再是全人群平均 μ_2 ，而按身高偏高/偏矮的程度修正： $\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ （身高越高、相关越强，修正越多）；同时因为知道了身高，不确定性变小：方差从 σ_2^2 缩到 $\sigma_2^2(1 - \rho^2)$ 。记住这两句话，公式就背下来了。

例题 3.2 条件分布法生成二维正态

用条件分布法生成 $N_2(\boldsymbol{\mu}, \Sigma)$ （参数同上例： $\sigma_1 = \sigma_2 = 2, \rho = 0.8, \boldsymbol{\mu} = \mathbf{0}$ ）。

【解】二维情形条件公式化简为：

$$X_1 \sim N(\mu_1, \sigma_1^2), \quad X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right).$$

代入数值： $X_1 \sim N(0, 4)$ ； $X_2 | X_1 = x_1 \sim N(0.8x_1, 4 \times 0.36) = N(0.8x_1, 1.44)$ 。

步骤：(i) 抽 $z_1 \sim N(0, 1)$ ，令 $x_1 = 2z_1$ ；(ii) 抽 $z_2 \sim N(0, 1)$ ，令 $x_2 = 0.8x_1 + 1.2z_2$ 。展开发现 $x_2 = 1.6z_1 + 1.2z_2$ ——与变换法完全一致！两种方法殊途同归。

3.4 多维舍选法

与一维完全平行：目标密度 $p(\mathbf{x})$ ，建议密度 $f(\mathbf{x})$ （常取各分量独立、容易抽的分布）， $M \geq \sup p/f$ ；抽 $\mathbf{y} \sim f$ 、 $u \sim U(0, 1)$ ， $u \leq \frac{p(\mathbf{y})}{Mf(\mathbf{y})}$ 则接受。

例题 3.3 单位圆盘上的均匀点

设计算法在单位圆盘 $\{x^2 + y^2 \leq 1\}$ 上抽均匀分布的点，并求接受概率。

【解】 在正方形 $[-1, 1]^2$ 上抽均匀点很容易: $x = 2u_1 - 1, y = 2u_2 - 1$ 。圆盘含于正方形内, 于是:
(i) 产生 $u_1, u_2 \sim U(0, 1)$, 令 $x = 2u_1 - 1, y = 2u_2 - 1$; (ii) 若 $x^2 + y^2 \leq 1$ 接受 (x, y) , 否则返回 (i)。

接受概率 = 圆盘面积/正方形面积 = $\pi/4 \approx 78.5\%$ 。被接受的点在圆盘内自动均匀 (均匀点限制在子区域上仍均匀)。

3.5 离散随机向量: 条件分布法大显身手

例题 3.4 放球问题 (课件原题)

把 n 个球独立地等概率放入 A、B、C 三个篮子。记 X 为落入 A 的个数、 Y 为落入 B 的个数。给出生成 (X, Y) 的方法。

【解】 边际: 每个球进 A 的概率 $1/3$, 故 $X \sim B(n, \frac{1}{3})$ 。条件: 已知 $X = x$, 剩下 $n - x$ 个球只在 B、C 中等可能选择, 进 B 概率 $\frac{1/3}{2/3} = \frac{1}{2}$, 故 $Y | X = x \sim B(n - x, \frac{1}{2})$ 。

步骤: (i) 抽 $x \sim B(n, 1/3)$; (ii) 抽 $y \sim B(n - x, 1/2)$; 输出 (x, y) 。

推广: 多项分布 $\text{Mult}(n; p_1, \dots, p_r)$ 。有放回取 n 次、每次落入第 i 类概率 p_i , X_i 为第 i 类计数。两种生成方式:

1. **逐次分类法**: 做 n 次离散查表抽样 (第 1 章方法), 统计各类频数;
2. **条件分布法**:

$$X_1 \sim B(n, p_1), \quad X_k | X_1, \dots, X_{k-1} \sim B\left(n - \sum_{i < k} x_i, \frac{p_k}{1 - \sum_{i < k} p_i}\right).$$

直觉: 抽掉前几类后, 剩余的球在剩余类别中按“重新归一化”的概率分配。

3.6 本章考点地图

高频题型清单

1. **变换法生成二维正态**: 默写 η_1, η_2 公式, 代数值并验证三个矩 (如 $\sigma_1 = \sigma_2 = 2, \rho = 0.8$);
2. **条件分布法生成二维正态**: 默写条件正态参数 $\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 、 $\sigma_2^2(1 - \rho^2)$, 写两步算法;
3. **离散向量条件分布法**: 放球/多项分布的逐分量条件二项分布;
4. **多维舍选**: 不规则区域上的均匀抽样 + 接受概率 (面积比);
5. **Jacobi 公式**: 用密度变换公式验证某变换的正确性。

4 第3章 参数估计的统计计算

4.1 故事：估计量自己也是个随机变量

数理统计课告诉我们：用 $\bar{X}$ 估 μ 、用 S^2 估 σ^2 。但你有没有想过——**估计量本身就是随机的**（换一批样本它就变一个值），那它”平均估得准不准”（期望/偏差）、”波动大不大”（方差）？

简单情形可以手算（ $\mathbb{E}\bar{X} = \mu, \text{Var}\bar{X} = \sigma^2/n$ ），可一旦估计量复杂一点（中位数？截断分布的均值？），理论分布根本推不动。本章的核心思想就一招：

理论推不动？那就让计算机**真的把”换一批样本”这件事重复一千遍**，看这一千个估计值的平均和波动——这就是估计量期望与方差的蒙特卡洛估计。

4.2 用 MC 估计估计量的期望与方差

核心算法（必背三步）

1. 从总体 X 生成一组容量 n 的样本 $X_{11}, \dots, X_{1n}$ ，算估计值 $\hat{\theta}^{(1)}$ ；
2. 独立重复 K 次，得 $\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(K)}$ ；
3. 汇总：

$$\widehat{\mathbb{E}(\hat{\theta})} = \frac{1}{K} \sum_{k=1}^K \hat{\theta}^{(k)}, \quad \widehat{\text{Var}(\hat{\theta})} = \frac{1}{K} \sum_{k=1}^K (\hat{\theta}^{(k)} - \bar{\hat{\theta}})^2, \quad \widehat{\text{Bias}} = \bar{\hat{\theta}} - \theta.$$

注意区分两个样本量： n 是**每组数据的容量**（统计问题本身的）， K 是**重复实验次数**（模拟精度的）。 K 越大，对 $\mathbb{E}\hat{\theta}$ 的估计越准。

人话解读

类比：想知道某位射手（估计量）的水平，就让他打 $K = 1000$ 轮比赛，每轮用 $n = 25$ 发子弹（一组样本）。看这 1000 个成绩的平均位置（期望）和散布（方差）。 n 是”每轮几发子弹”，是题目规定的； K 是”比多少轮”，是你自己定的、越多越准。考试里把 n 和 K 写反是最常见的丢分点！

例题 4.1 MC 验证 $\bar{X}$ 的性质

设 $X \sim N(5, 4)$, $n = 25$ 。设计 MC 实验验证 $\mathbb{E}\bar{X} = 5$ 、 $\text{Var}\bar{X} = 4/25 = 0.16$ ，并说明结果的精度。

【解】实验设计：(i) 生成 25 个 $N(5, 4)$ 随机数 ($x = 5 + 2z$, z 由 Box-Muller 产生)，算 $\bar{x}^{(1)}$ ；(ii) 重复 $K = 1000$ 次；(iii) 算 $\frac{1}{K} \sum \bar{x}^{(k)}$ (应 ≈ 5) 和 $\frac{1}{K} \sum (\bar{x}^{(k)} - \bar{\bar{x}})^2$ (应 ≈ 0.16)。

精度： $\bar{x}$ 自身的标准差为 $\sqrt{\text{Var}(\bar{X})/K} = \sqrt{0.16/1000} \approx 0.0126$ ，故 MC 结果会在 5 ± 0.013 左右波动，与理论值吻合即验证成功。

例题 4.2 MC 比较两个估计量

正态总体 $N(\mu, \sigma^2)$ 下，样本均值 $\bar{X}$ 与样本中位数 m 都能估 μ 。设计 MC 实验比较谁更好。

【解】 评价标准用 $MSE = Bias^2 + Var$ 。设计：(i) 生成 n 个 $N(\mu, \sigma^2)$ 数据，同时算出 $\bar{x}^{(k)}$ 和 $m^{(k)}$ ；(ii) 重复 K 次；(iii) 分别算 $\widehat{MSE}(\bar{X}) = \frac{1}{K} \sum (\bar{x}^{(k)} - \mu)^2$ 、 $\widehat{MSE}(m) = \frac{1}{K} \sum (m^{(k)} - \mu)^2$ ，小者更优。

预期结论： 正态总体下两者都近似无偏，但 $Var(m) \approx \frac{\pi}{2} \cdot \frac{\sigma^2}{n} \approx 1.57 Var(\bar{X})$ ，均值胜出。(但若总体是重尾的柯西分布，均值彻底失效、中位数稳健——MC 实验能直观展示这一点。)

4.3 置信区间：先复习公式，再用 MC 检验它

故事继续。 “置信区间承诺”以 95% 的概率罩住真参数”。这个承诺靠的是推导时的分布假设（正态总体、大样本近似……）。假设不满足时，承诺还兑现吗？——又是理论难算、模拟好办的问题。先把要检验的“公式”列全。

单总体正态 $N(\mu, \sigma^2)$ 的区间（置信水平 $1 - \alpha$ ）

- 估 μ , σ^2 已知：枢轴量 $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$,

$$\bar{X} \pm u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}.$$

- 估 μ , σ^2 未知：枢轴量 $\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$,

$$\bar{X} \pm t_{1-\alpha/2}(n-1) \frac{S}{\sqrt{n}}.$$

- 估 σ^2 ：枢轴量 $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$,

$$\left[\frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)} \right].$$

总体比例与两总体

- 比例 p (大样本)：由 CLT, $\hat{p} = \bar{X} \sim N(p, \frac{p(1-p)}{n})$,

$$\hat{p} \pm u_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}.$$

- 两正态均值差 (方差已知)： $\bar{X} - \bar{Y} \pm u_{1-\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$;

- 两正态均值差 (方差未知但相等)：合并方差 $S_w^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}$,

$$\bar{X} - \bar{Y} \pm t_{1-\alpha/2}(n_1+n_2-2) S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}};$$

- 方差比： $\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1-1, n_2-1)$ 。

例题 4.3 置信区间计算

某正态总体抽得 $n = 16$ 个数据, $\bar{x} = 10.2$, $s = 2.4$ 。求 μ 的 95% 置信区间 ($t_{0.975}(15) = 2.131$)。

【解】 σ 未知用 t 区间:

$$10.2 \pm 2.131 \times \frac{2.4}{\sqrt{16}} = 10.2 \pm 2.131 \times 0.6 = 10.2 \pm 1.28,$$

即 [8.92, 11.48]。含义: 按这种方法构造的区间, 长期来看约 95% 的次数能罩住真值 μ (不是“ μ 有 95% 概率在这个具体区间里”—— μ 是常数!)。

人话解读

所有置信区间都长一个样: **估计值 $\pm$ 分位数 $\times$ 估计值的标准差**。套公式只问三个问题: (1) 估谁? (均值/方差/比例) (2) σ 知不知道? (知道用 u 分位数, 不知道用 t) (3) 几个总体? 答完就能锁定唯一公式。上例中: 估均值、 σ 未知、单总体 $\Rightarrow \bar{x} \pm t_{0.975}(n-1)s/\sqrt{n}$ 。

4.4 用 MC 估计置信区间的覆盖率

算法 (必背)

给定真参数 (如 μ_0, σ_0) 与名义水平 $1 - \alpha$:

1. 从总体生成容量 n 的样本, 按公式算出区间 $[\hat{\theta}_L^{(k)}, \hat{\theta}_U^{(k)}]$;
2. 记录指示变量 $I_k = I(\hat{\theta}_L^{(k)} \leq \theta_0 \leq \hat{\theta}_U^{(k)})$;
3. 重复 K 次, 覆盖率估计为 $\frac{1}{K} \sum_k I_k$, 与 $1 - \alpha$ 对照。

例题 4.4 覆盖率实验设计 (综合题)

设计 MC 实验考察: “总体其实是指数分布 $\text{Exp}(1)$, 却照用正态 t 区间估均值”时, 95% 区间的实际覆盖率如何?

【解】真均值 $\theta_0 = 1$ 。(i) 用逆变换 $x = -\ln u$ 生成 n 个 $\text{Exp}(1)$ 数据; (ii) 算 $\bar{x}, s$, 构造 $\bar{x} \pm t_{0.975}(n-1)s/\sqrt{n}$; (iii) 记录是否覆盖 1; 重复 $K = 1000$ 次求覆盖频率。

预期结论: n 小 (如 $n = 10$) 时总体严重偏态, 覆盖率会低于 95% (区间“失信”); n 增大后由 CLT 覆盖率回升到接近 95%。这个实验展示了 MC 方法检验统计程序**稳健性**的威力。

4.5 本章考点地图

高频题型清单

1. 默写 MC 估计估计量期望/方差的三步算法 (分清 n 与 K !);
2. 设计 MC 实验比较估计量 (标准: $\text{MSE} = \text{Bias}^2 + \text{Var}$);
3. 置信区间公式默写 + 数值计算 (四套枢轴量: u, t, χ^2, F , 外加比例的 CLT 近似);
4. 设计覆盖率 MC 实验并解释覆盖率偏离名义水平的含义;
5. 概念题: 置信区间的频率解释; 无偏性/有效性/相合性。

5 第4章 假设检验的统计计算

5.1 故事：检验的”灵敏度”也得靠模拟来量

假设检验像一台”测谎仪”： H_0 是嫌疑人的供词，数据是证据。仪器有两个关键指标：

- **误报率**（第一类错误概率 α ）：供词是真的却报警；
- **灵敏度**（功效 $1 - \beta$ ）：供词是假的能否报警。

α 是我们设定的，但**功效往往没有公式可算**——它取决于真实参数离 H_0 有多远、样本量多大、总体什么形状。第一部分就教你用 MC 把这两个指标”量”出来。第二部分集结一批**非参数检验**：不依赖总体正态假设的实用检验法。

5.2 MC 估计第一类错误概率与功效

引例（贯穿本节）。 $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, 1)$ ，检验

$$H_0: \mu = 0 \quad vs \quad H_1: \mu \neq 0.$$

统计量 $T = \sqrt{n} \bar{X}$ ， H_0 下 $T \sim N(0, 1)$ ，水平 α 的拒绝域为 $|T| > u_{1-\alpha/2}$ 。

MC 估计第一类错误率（在 H_0 下做实验）

1. 取 $\mu = 0$ (H_0 为真)，生成 n 个 $N(0, 1)$ 数据，算 T ，记录是否 $|T| > u_{1-\alpha/2}$ ；
2. 重复 K 次（如 $K = 1000$ ）；
3. $\hat{\alpha} = \frac{\text{拒绝次数}}{K}$ ，应接近名义 α 。

MC 估计功效（在 H_1 下做实验）

1. 取 H_1 中某个具体的 $\mu = \mu_1 \neq 0$ （如 0.5），生成数据、算 T 、记录是否拒绝；
2. 重复 K 次， $\widehat{1 - \beta} = \frac{\text{拒绝次数}}{K}$ 。

对一串 μ_1 值各算一遍，连起来就是**功效函数曲线**： μ_1 离 0 越远、 n 越大，功效越接近 1。

最容易混的一点

估 α ：数据在 H_0 的**参数**下生成；估功效：数据在 H_1 的**具体参数**下生成。两个实验的”判断是否拒绝”步骤完全相同，区别只在数据从哪儿来！

人话解读

测谎仪类比：想知道仪器的**误报率**，就找一批**诚实的人**（ H_0 为真， $\mu = 0$ 生成数据）来测，数被误报的比例；想知道**灵敏度**（功效），就找一批**说谎的人**（ H_1 为真，如 $\mu = 0.5$ 生成数据）来测，数被抓出的比例。仪器本身（拒绝规则）不变，变的只是”送进去测的人”。

例题 5.1 功效模拟实战

上述引例中取 $n = 25$, $\alpha = 0.05$, $\mu_1 = 0.5$ 。(1) 写出 MC 估计功效的步骤；(2) 本例其实有理论功效，算出来对照。

【解】 (1) 每轮：生成 25 个 $N(0.5, 1)$ 数据 $\rightarrow T = 5\bar{x} \rightarrow$ 记录 $|T| > 1.96$ 与否；重复 $K = 1000$ 轮，功效估计为拒绝频率。

(2) $\mu = 0.5$ 时 $T = \sqrt{n}\bar{X} \sim N(\sqrt{n}\mu, 1) = N(2.5, 1)$,

$$\begin{aligned} 1 - \beta &= \mathbb{P}(|T| > 1.96) = \mathbb{P}(T > 1.96) + \mathbb{P}(T < -1.96) \approx \Phi(2.5 - 1.96) + \Phi(-1.96 - 2.5) \\ &= \Phi(0.54) + \Phi(-4.46) \approx 0.705 + 0.000 \approx 0.71. \end{aligned}$$

模拟结果应在 0.71 附近波动（标准差约 $\sqrt{0.71 \times 0.29/1000} \approx 0.014$ ）。

5.3 单样本检验：数据像不像某个分布？**5.3.1 χ^2 拟合优度检验**

想法。 把数轴切成 r 个格子，数一数每格观测频数 n_i 与“假设分布预言的频数” np_i 差多远，差得太离谱就不信 H_0 。

统计量与拒绝规则

$$\chi^2 = \sum_{i=1}^r \frac{(n_i - np_i)^2}{np_i} \stackrel{H_0}{\approx} \chi^2(r-1-s),$$

s 为用样本估计的未知参数个数。 $\chi^2 > \chi^2_{1-\alpha}(r-1-s)$ 时拒绝。**使用条件：**每格期望频数 $np_i \geq 5$ （不足就合并相邻格子）。

人话解读

逐项拆解： n_i 是“实际数出来多少个”， np_i 是“如果 H_0 是真的、理论上该有多少个”。每一格算 $(\text{实际} - \text{理论})^2 / \text{理论}$ ，再全部加起来——这就是“总偏离分数”。分数小说明观测和理论吃得消，不拒绝；分数大到超过查表临界值，就说明“偏得离谱，不像是运气问题”，拒绝 H_0 。自由度口诀：格子数 - 1 - 估计的参数个数。

例题 5.2 骰子均匀吗？

掷骰子 120 次，六个点数出现 25, 18, 21, 16, 24, 16 次。在 $\alpha = 0.05$ 下检验骰子是否均匀 ($\chi^2_{0.95}(5) = 11.07$)。

【解】 H_0 ：各面概率 $1/6$ ，期望频数 $np_i = 20$ 。

$$\chi^2 = \frac{(25-20)^2 + (18-20)^2 + (21-20)^2 + (16-20)^2 + (24-20)^2 + (16-20)^2}{20} = \frac{25 + 4 + 1 + 16 + 16 + 16}{20} =$$

自由度 $r-1 = 5$ （无估计参数， $s = 0$ ）。 $3.9 < 11.07$ ，不拒绝 H_0 ：没有证据说骰子不均匀。

5.3.2 单样本 Kolmogorov–Smirnov (K–S) 检验

不分格子，直接比较**经验分布函数** $F_n(x) = \frac{1}{n} \# \{i: X_i \leq x\}$ 与假设分布 $F_0(x)$ 的最大距离：

$$D_n = \sup_x |F_n(x) - F_0(x)|,$$

D_n 超过临界值则拒绝。与 χ^2 对比：K–S 无需分组、保留全部信息、小样本也好用，适合**连续**分布； χ^2 适合离散/分组数据、大样本。

5.3.3 随机性检验：变号检验与游程检验

检验一系列数据是不是“纯随机”（无趋势、无周期）。

- **变号检验**：数相邻差值的符号变化次数，与随机序列的理论期望比较；
- **游程检验**：按高于/低于中位数把序列变成 0–1 串，**游程** = 连续相同符号的一段。设 1 有 m 个、0 有 n 个，总游程数 R 满足

$$\mathbb{E}R = \frac{2mn}{m+n} + 1, \quad \text{Var}R = \frac{2mn(2mn - m - n)}{(m+n)^2(m+n-1)},$$

大样本下 $Z = \frac{R - \mathbb{E}R}{\sqrt{\text{Var}R}} \sim N(0, 1)$ 。游程太少（数据成片聚集，有趋势）或太多（剧烈交替，有负相关）都拒绝随机性。

5.4 两样本检验：两组数据来自同一总体吗？

5.4.1 Mann–Whitney U 检验（秩和检验）

想法。把两组数据混在一起排名次。如果两总体相同，两组的名次应当“你中有我、我中有你”；若 X 组名次系统性偏大，说明 X 总体位置偏高。

统计量

记 W 为 X 组（容量 m ）在混合样本中的秩和，

$$U = W - \frac{m(m+1)}{2} \quad (\text{等于“} X_i > Y_j \text{ 的对子数”}).$$

H_0 （同分布）下 $\mathbb{E}U = \frac{mn}{2}$, $\text{Var}U = \frac{mn(m+n+1)}{12}$ ，大样本用 $Z = \frac{U - \mathbb{E}U}{\sqrt{\text{Var}U}} \sim N(0, 1)$ 。适合检验**位置（中位数）**差异，完全不需要正态假设。

人话解读

类比跳远比赛：两个班的同学混在一起按成绩排名次。如果两个班水平相同，名次应该交错分布；如果某班的名次整体靠前，说明这个班更强。 W 就是 X 班的“名次总和”， U 是把它标准化成“ X 赢 Y 的对子数”。只用名次不用原始数值，所以不怕总体不是正态、也不怕个别极端值。

例题 5.3 U 检验计算

X 组：1.1, 2.3, 3.5 ($m = 3$)； Y 组：1.8, 4.2, 5.0, 5.6 ($n = 4$)。计算 U 并写出大样本检验的做法。

【解】混合排序: 1.1(X), 1.8(Y), 2.3(X), 3.5(X), 4.2(Y), 5.0(Y), 5.6(Y), X 组的秩为 1, 3, 4, $W = 8$ 。

$$U = W - \frac{m(m+1)}{2} = 8 - 6 = 2.$$

(验证: 逐对数 $X_i > Y_j$ 的对子: $2.3 > 1.8$, $3.5 > 1.8$, 共 2 对, 一致。) $EU = \frac{3 \times 4}{2} = 6$, $\text{Var}U = \frac{3 \times 4(3+4+1)}{12} = 8$, $Z = \frac{2-6}{\sqrt{8}} \approx -1.41$ 。 $|Z| < 1.96$, $\alpha = 0.05$ 下不拒绝两总体相同 (样本太小, 实际应查精确表)。

5.4.2 两样本 K-S 检验与两样本游程检验

- **两样本 K-S:** $D_{m,n} = \sup_x |F_m(x) - G_n(x)|$, 两个经验分布函数的最大差距。对位置、尺度、形状的差异全都敏感, 是”全能型”检验。
- **两样本游程检验:** 混合排序后按来源标成 0-1 串数游程 R 。两总体相同 $\Rightarrow$ 充分混杂 $\Rightarrow R$ 大; R 显著偏小则拒绝。 $ER, \text{Var}R$ 公式同前 (m, n 为两组容量)。

5.5 独立性检验: 两个变量有没有关系?

5.5.1 列联表 χ^2 检验

统计量

$r \times c$ 列联表, 观测频数 n_{ij} , 行和 $n_{i\cdot}$ 、列和 $n_{\cdot j}$ 、总数 n 。 H_0 (行列独立) 下第 (i, j) 格的期望频数为

$$\hat{e}_{ij} = \frac{n_{i\cdot} \cdot n_{\cdot j}}{n} \quad (\text{独立} \Rightarrow p_{ij} = p_{i\cdot} p_{\cdot j}),$$

$$\chi^2 = \sum_{i,j} \frac{(n_{ij} - \hat{e}_{ij})^2}{\hat{e}_{ij}} \stackrel{H_0}{\approx} \chi^2((r-1)(c-1)).$$

例题 5.4 列联表检验计算

调查 200 人, 性别与”是否喜欢某产品”的 2×2 表为: 男 (喜欢 60, 不喜欢 40), 女 (喜欢 40, 不喜欢 60)。 $\alpha = 0.05$ 检验性别与偏好是否独立 ($\chi_{0.95}^2(1) = 3.84$)。

【解】行和: 男 100、女 100; 列和: 喜欢 100、不喜欢 100。期望频数全部为 $\hat{e}_{ij} = \frac{100 \times 100}{200} = 50$ 。

$$\chi^2 = \frac{(60 - 50)^2}{50} \times 2 + \frac{(40 - 50)^2}{50} \times 2 = 2 + 2 + 2 + 2 = 8.$$

自由度 $(2-1)(2-1) = 1$, $8 > 3.84$, 拒绝独立性: 性别与偏好显著相关。

5.5.2 相关系数检验

二维正态样本, 检验 $H_0: \rho = 0$ 。样本相关系数 r , 统计量

$$T = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \stackrel{H_0}{\sim} t(n-2),$$

$|T| > t_{1-\alpha/2}(n-2)$ 则认为线性相关显著。非正态数据可改用 Spearman 秩相关。

5.6 本章考点地图

高频题型清单

1. 默写 MC 估计 α /功效的算法，强调数据生成参数的区别（最高频）；
2. χ^2 拟合优度数值题：算统计量、定自由度（减 $s!$ ）、查表下结论；
3. 列联表数值题：期望频数 $\hat{e}_{ij} = n_{i \cdot} n_{\cdot j} / n$ 、自由度 $(r-1)(c-1)$ ；
4. U 检验/游程检验：秩和 $\rightarrow U \rightarrow$ 正态近似；游程数的均值方差公式；
5. 方法选择题：场景对号入座——拟合优度（ χ^2 /K-S）、随机性（游程）、两样本位置（U）、两样本同分布（两样本 K-S/游程）、独立性（列联表 χ^2 /相关系数 t 检验）。

6 第 5 章 方差缩减技术

6.1 故事：MC 的”省钱秘籍”

蒙特卡洛估计的误差 $\propto \sigma/\sqrt{n}$ 。想把误差减小到 $1/10$ ？样本量要乘 100——这是”花钱”的笨办法。聪明的办法是在 n 不变的前提下把 σ 压下去：同样的计算量换更高的精度，这就是方差缩减（variance reduction）。

本章的统一目标：估计积分/期望

$$I = \int_0^1 f(x) dx = \mathbb{E} f(U), \quad U \sim U(0, 1).$$

每种技术都是一种”省钱”思路，学的时候抓住两点：为什么方差变小了、怎么操作。

6.2 出发点：投点法 vs 平均值法

投点法 (hit-or-miss)。 设 $0 \leq f \leq 1$ 。往单位正方形里均匀投 n 个点 (U_i, V_i) ，数落在曲线下方 ($V_i \leq f(U_i)$) 的比例：

$$\hat{I}_1 = \frac{1}{n} \sum_i I(V_i \leq f(U_i)), \quad \text{Var}(\hat{I}_1) = \frac{I(1-I)}{n}.$$

平均值法 (sample mean)。 直接把 I 看成期望，取

$$\hat{I}_2 = \frac{1}{n} \sum_i f(U_i), \quad \text{Var}(\hat{I}_2) = \frac{1}{n} \left(\int_0^1 f^2 dx - I^2 \right).$$

定理：平均值法永不吃亏

若 $0 \leq f(x) \leq 1$ ，则 $\text{Var}(\hat{I}_2) \leq \text{Var}(\hat{I}_1)$ 。

证明： $0 \leq f \leq 1 \Rightarrow f^2 \leq f$ ，故 $\int f^2 dx \leq \int f dx = I$ ，于是

$$\text{Var}(\hat{I}_2) = \frac{\int f^2 - I^2}{n} \leq \frac{I - I^2}{n} = \frac{I(1-I)}{n} = \text{Var}(\hat{I}_1). \quad \blacksquare$$

直觉：投点法把 $f(U_i)$ 这个连续信息压缩成“中/不中”一个比特，浪费了信息；平均值法用全了，自然更准。

例题 6.1 两法方差对比

估计 $I = \int_0^1 x \, dx = \frac{1}{2}$ 。分别算投点法与平均值法的方差，求方差缩减比。

【解】投点法： $\text{Var}(\hat{I}_1) = \frac{I(1-I)}{n} = \frac{1/4}{n} = \frac{0.25}{n}$ 。

平均值法： $\int_0^1 x^2 \, dx = \frac{1}{3}$ ， $\text{Var}(\hat{I}_2) = \frac{1}{n} \left(\frac{1}{3} - \frac{1}{4} \right) = \frac{1/12}{n} \approx \frac{0.083}{n}$ 。

缩减比 $= 0.25/0.083 = 3$ ：平均值法等于白赚了 3 倍样本量。

6.3 对偶变量法 (antithetic variates)

直觉先行。 两个估计量平均的方差：

$$\text{Var}\left(\frac{X+Y}{2}\right) = \frac{\text{Var}X + \text{Var}Y + 2\text{Cov}(X,Y)}{4}.$$

若 X, Y 负相关， $\text{Cov} < 0$ ，平均后的方差比独立时还小——“一个偏高时另一个偏低，互相抵消”。

操作

U 与 $1-U$ 同为 $U(0,1)$ 但完全负相关。取

$$\hat{I} = \frac{1}{2n} \sum_{i=1}^n [f(U_i) + f(1-U_i)].$$

当 f 单调时， $f(U)$ 与 $f(1-U)$ 负相关，必有方差缩减；且每对只花一个随机数，等于“买一送一”。

人话解读

抬桌子类比：一个人端盘子会抖（误差大），两个人抬且“你往左晃时我恰好往右晃”（负相关），盘子就稳了。 U 和 $1-U$ 就是这样一对“反着抖”的搭档： U 抽到偏大的， $1-U$ 必然偏小， f 单调时两个函数值一高一低，平均后误差大幅抵消。

例题 6.2 对偶法估计 $\int_0^1 e^x \, dx$

比较朴素平均值法与对偶法（同为 $2n$ 次函数求值）的方差。已知 $\mathbb{E}e^U = e - 1 \approx 1.718$ ， $\text{Var}(e^U) = \frac{e^2-1}{2} - (e-1)^2 \approx 0.242$ ， $\text{Cov}(e^U, e^{1-U}) = e - (e-1)^2 \approx -0.234$ 。

【解】朴素法用 $2n$ 个独立 U ： $\text{Var} = \frac{0.242}{2n} = \frac{0.121}{n}$ 。

对偶法：单对的方差

$$\text{Var}\left(\frac{e^U + e^{1-U}}{2}\right) = \frac{0.242 + 0.242 + 2 \times (-0.234)}{4} = \frac{0.016}{4} = 0.0039,$$

n 对平均后 $\text{Var} = \frac{0.0039}{n}$ 。缩减比 $0.121/0.0039 \approx 31$ 倍！ e^x 单调性强，负相关抵消效果极好。

6.4 控制变量法 (control variates)

直觉先行。 想估 $\mathbb{E}X$, 手头另有一个与 X 相关、且期望已知的变量 Y ($\mathbb{E}Y = \mu_Y$)。 Y 的模拟误差 $Y - \mu_Y$ 是可观测的”风向标”—— X 与 Y 正相关时, Y 偏高大概率 X 也偏高, 把这部分误差扣掉:

$$X(c) = X - c(Y - \mu_Y).$$

无论 c 取多少都无偏 (因 $\mathbb{E}(Y - \mu_Y) = 0$), 挑 c 让方差最小。

最优系数 (必背推导)

$$\text{Var}X(c) = \text{Var}X - 2c\text{Cov}(X, Y) + c^2\text{Var}Y$$

是 c 的开口向上抛物线, 求导置零得

$$c^* = \frac{\text{Cov}(X, Y)}{\text{Var}Y}, \quad \text{Var}X(c^*) = \text{Var}X(1 - \rho_{XY}^2).$$

相关越强 ($|\rho| \rightarrow 1$), 缩减越狠。实际中 Cov, Var 用样本估计。

人话解读

考试生类比: 想估某同学真实水平 ($\mathbb{E}X$), 但这次考题整体偏难。怎么知道偏了多少? 看一个”参照生” Y : 他的真实水平 μ_Y 我们早就知道, 他这次考了 Y 分, 那么 $Y - \mu_Y$ 就是”这次考题的偏差”, 把它按比例 c 从目标同学分数里扣掉即可。 $c^* = \text{Cov}/\text{Var}$ 只是在问: ”两人受考题影响的联动有多强, 就扣多大比例。”

例题 6.3 控制变量法估计 $\int_0^1 e^x dx$

取 $X = e^U$, 控制变量 $Y = U$ ($\mathbb{E}U = \frac{1}{2}$ 已知)。已知 $\text{Cov}(e^U, U) = 1 - \frac{e-1}{2} \cdot 1 \approx 0.1409$ (即 $\mathbb{E}[Ue^U] - \mathbb{E}U\mathbb{E}e^U = 1 - (e-1)/2$), $\text{Var}U = \frac{1}{12}$, $\text{Var}e^U \approx 0.242$ 。求 c^* 与方差缩减比。

【解】

$$c^* = \frac{\text{Cov}(e^U, U)}{\text{Var}U} = \frac{0.1409}{1/12} \approx 1.69.$$

$$\text{相关系数 } \rho = \frac{0.1409}{\sqrt{0.242 \times 1/12}} \approx 0.992,$$

$$\text{Var}X(c^*) = 0.242 \times (1 - 0.992^2) \approx 0.242 \times 0.016 \approx 0.0039,$$

缩减约 60 倍。估计量为 $\frac{1}{n} \sum [e^{U_i} - 1.69(U_i - \frac{1}{2})]$ 。直线 $1.69(u - \frac{1}{2}) + \text{const}$ 把 e^u 拟合得很好, 残差自然小。

6.5 条件期望法 (Rao-Blackwell 化)

直觉先行。 全方差分解:

$$\text{Var}X = \mathbb{E}[\text{Var}(X | Y)] + \text{Var}[\mathbb{E}(X | Y)].$$

两项都非负, 所以 $\text{Var}[\mathbb{E}(X | Y)] \leq \text{Var}X$, 而 $\mathbb{E}[\mathbb{E}(X | Y)] = \mathbb{E}X$ (无偏不变)。结论: **凡是能解析地算出来的部分就别模拟**——用 $\mathbb{E}(X | Y)$ 替代 X , 把” Y 给定后 X 的随机性”整个消灭掉。

人话解读

一句话：**能用笔算的部分就别抽签了**。估 π 的例子中，原来要抽两个随机数 (U, V) 看点在不在圆内；但其实 U 定下后，“ V 落在圆内”的概率精确等于 $\sqrt{1-U^2}$ ，这一步根本不用抽——直接用公式。少抽一次签，少一份随机性，方差自然小。

例题 6.4 条件期望法估计 π

投点法估 π : (U, V) 均匀于 $[0, 1]^2$, $X = I(U^2 + V^2 \leq 1)$, $\mathbb{E}X = \pi/4$ 。用条件期望法改进之。

【解】对 U 取条件：

$$g(U) = \mathbb{E}[X | U] = \mathbb{P}(V \leq \sqrt{1-U^2} | U) = \sqrt{1-U^2}.$$

改用 $\hat{\theta} = \frac{1}{n} \sum \sqrt{1-U_i^2}$ (只需一半随机数!)。方差对比: $\text{Var}X = \frac{\pi}{4}(1 - \frac{\pi}{4}) \approx 0.169$; $\text{Var}\sqrt{1-U^2} = \mathbb{E}(1-U^2) - (\pi/4)^2 = \frac{2}{3} - 0.617 \approx 0.0498$ 。缩减约 3.4 倍，且每次抽样成本减半。

6.6 重要抽样法 (importance sampling)

直觉先行。 $I = \int f(x) dx$ 中，若 f 只在一小块区域大、其他地方几乎为 0，均匀抽样的大部分点都“浪费”在不重要的区域。不如按一个密度 g (形状接近 f) 抽样，多去重要区域，再用权重纠偏：

$$I = \int \frac{f(x)}{g(x)} g(x) dx = \mathbb{E}_g \left[\frac{f(X)}{g(X)} \right] \Rightarrow \hat{I} = \frac{1}{n} \sum_i \frac{f(X_i)}{g(X_i)}, \quad X_i \sim g.$$

人话解读

找鱼类比：湖里的鱼（被积函数的“质量”）集中在东南角，均匀撒网是浪费；聪明的做法是哪里鱼多往哪里多撒网（按 g 抽样）。但多撒了网会高估鱼量，所以每网收获要除以“这里撒网的加密倍数”（除以 g ）来纠偏。唯一的雷：有鱼的地方几乎不撒网（ $f > 0$ 处 $g \approx 0$ ），一旦撞上权重爆炸。

要点

- g 与 f/I 越像， f/g 越接近常数，方差越小（理想极限： $g \propto |f|$ 时方差为 0，但需要知道 I ，做不到，只能逼近）；
- **大忌**： g 的尾巴比 f 轻（ $f > 0$ 处 $g \approx 0$ ），权重 f/g 爆炸，方差反而无穷大。

例题 6.5 重要抽样估计 $\int_0^1 e^x dx$

取 $g(x) = \frac{2}{3}(1+x)$ ($0 \leq x \leq 1$ 上的密度)。写出估计量并说明为何方差小。

【解】 g 是归一化的 $1+x$: $\int_0^1 (1+x) dx = \frac{3}{2}$, 故 $g = \frac{2}{3}(1+x)$ 。抽 $X \sim g$ (逆变换: $G(x) = \frac{2}{3}(x + \frac{x^2}{2}) = u$, 解 $x = \sqrt{1+3u} - 1$),

$$\hat{I} = \frac{1}{n} \sum_i \frac{e^{X_i}}{\frac{2}{3}(1+X_i)}.$$

因为 $e^x \approx 1+x$ (泰勒展开)，比值 $\frac{e^x}{1+x}$ 在 $[0, 1]$ 上仅在 $[1, e/2 \approx 1.36]$ 间变化，远比 $e^x \in [1, e]$ 平稳，方差显著小于朴素平均值法。

6.7 分层抽样法 (stratified sampling)

直觉先行。 全国调查收入，纯随机抽样可能恰好多抽了富人——不如**先分层、层内定额**：每层抽固定数量，层间差异（方差的“between”部分）被彻底消灭，只剩层内方差。

操作（等分层为例）

把 $[0, 1]$ 切成 m 段，第 j 段抽 n_j 个均匀点 ($\sum n_j = n$)，

$$\hat{I} = \sum_{j=1}^m \frac{1}{m} \cdot \frac{1}{n_j} \sum_{i=1}^{n_j} f(X_{ij}), \quad X_{ij} \sim U\left(\frac{j-1}{m}, \frac{j}{m}\right).$$

由全方差分解，分层（按比例分配）后方差 $\leq$ 简单随机抽样的方差；按“层标准差大的多抽”（Neyman 分配）还能更优。

例题 6.6 分层抽样的效果

估计 $I = \int_0^1 x \, dx$ 。把 $[0, 1]$ 等分两层各抽 $n/2$ 个点，与不分层（ n 个点）比较方差。

【解】 不分层： $\text{Var} = \frac{\text{Var}U}{n} = \frac{1/12}{n}$ 。

分层：每层是宽 $\frac{1}{2}$ 的均匀分布，层内方差 $\frac{(1/2)^2}{12} = \frac{1}{48}$ 。

$$\text{Var}(\hat{I}) = \frac{1}{4} \left(\frac{1/48}{n/2} + \frac{1/48}{n/2} \right) = \frac{1}{48n}.$$

缩减比 $\frac{1/12}{1/48} = 4$ 倍。直觉： $f(x) = x$ 的差异主要在“层间”（左半小右半大），分层把这部分方差直接清零。

6.8 公共随机数法 (common random numbers)

场景不同于前面：**比较**两个系统 $\theta_1 - \theta_2$ 。

$$\text{Var}(X - Y) = \text{Var}X + \text{Var}Y - 2\text{Cov}(X, Y),$$

让两个系统用**同一串随机数**模拟，制造**正相关**，差的方差就小——“同一套考题考两个学生，分差更能反映真实水平”。（注意与对偶变量法相反：比较问题要正相关，求和/平均问题要负相关。）

6.9 本章考点地图

高频题型清单

1. **证明平均值法优于投点法** ($f^2 \leq f$ 三行证明，必考)；
2. **对偶变量法**：写估计量 + 用 $\text{Cov} < 0$ 说明方差缩减；给数值算缩减比；
3. **控制变量法**：推导 $c^* = \text{Cov}/\text{Var}$ 与 $\text{Var}_{\min} = \text{Var}X(1 - \rho^2)$ （高频大题）；
4. **条件期望法**：全方差分解一行定理 + 构造 $\mathbb{E}(X | Y)$ （如 $\sqrt{1 - U^2}$ 估 π ）；
5. **重要抽样**：写加权估计量、说明 g 的选取原则与尾部陷阱；
6. **方法匹配概念题**：每种方法各自的适用场景与直觉一句话。

7 第 6 章 Bootstrap 与 Jackknife

7.1 故事：没有总体，怎么”重复实验”？

第 3 章评估估计量的套路是”从总体反复抽样”。可现实中我们**根本不知道总体**，手里只有一份数据 $x_1, \dots, x_n$ 。重复实验做不了，难道就没法知道 $\hat{\theta}$ 的标准误了吗？

Efron (1979) 的天才想法：既然不知道总体 F ，就用**经验分布 F_n 冒充总体**——把手里的 n 个数据点各赋 $1/n$ 概率当成一个”小总体”，从它有放回地抽样来模拟”重复实验”。这就像”拔着自己的鞋带把自己提起来” (bootstrap 的字面意思)，听着离谱，但理论证明： n 不太小时 $F_n \approx F$ ，模拟出的波动确实近似真实波动。

MC (第 3 章) vs Bootstrap (本章) 一句话对比

- MC 模拟：总体已知 $\rightarrow$ 从**真总体**反复抽新样本；
- Bootstrap：总体未知 $\rightarrow$ 从**经验分布 F_n** (即原样本本身) 有放回重抽。

人话解读

抽奖箱类比：把手里的 n 个数据写在 n 张纸条上扔进箱子。每次”重复实验”就是：从箱里摸一张、记下数字、**放回去**、再摸……共摸 n 次。所以同一个数据可能被抽到好几次、有的一次没抽到——这很正常，不是错误。每摸完一轮算一个 $\hat{\theta}^*$ ，重复 B 轮，看这 B 个值抖得多厉害，就知道 $\hat{\theta}$ 有多不靠谱。

7.2 Bootstrap 估计标准误与偏差

核心算法 (必背)

1. 从原样本 $\{x_1, \dots, x_n\}$ 中有放回抽 n 个，得 Bootstrap 样本 $x^{*(1)}$ ，算 $\hat{\theta}^{*(1)}$ ；
2. 重复 B 次 (常取 $B = 1000$) 得 $\hat{\theta}^{*(1)}, \dots, \hat{\theta}^{*(B)}$ ；
3. 汇总 (记 $\bar{\theta}^* = \frac{1}{B} \sum_b \hat{\theta}^{*(b)}$):

$$\widehat{se}_B = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}^{*(b)} - \bar{\theta}^*)^2}, \quad \widehat{\text{Bias}}_B = \bar{\theta}^* - \hat{\theta}.$$

偏差校正估计: $\tilde{\theta} = \hat{\theta} - \widehat{\text{Bias}}_B = 2\hat{\theta} - \bar{\theta}^*$ 。

为什么偏差是 $\bar{\theta}^* - \hat{\theta}$? 真实世界里偏差是 $\mathbb{E}_F \hat{\theta} - \theta$: ”样本上的估计”平均偏离”总体真值”多少。Bootstrap 世界里把 F_n 当总体，其”真值”就是 $\hat{\theta}$ ，”样本上的估计”就是 $\hat{\theta}^*$ ，于是偏差被模拟为 $\bar{\theta}^* - \hat{\theta}$ 。**记忆口诀：Bootstrap 世界整体往下平移一层** ($F \rightarrow F_n, \theta \rightarrow \hat{\theta}, \hat{\theta} \rightarrow \hat{\theta}^*$)。

人话解读

平移对照表 (考试直接套): 真实世界里”总体 $\rightarrow$ 样本 $\rightarrow$ 估计值”，Bootstrap 世界里对应”原样本 $\rightarrow$ 重抽样本 $\rightarrow \hat{\theta}^*$ ”。你想知道哪个量 (比如 $\hat{\theta} - \theta$ 的分布)，就把里面每个符号各降一级

(变成 $\hat{\theta}^* - \hat{\theta}$), 后者能用计算机算出一大堆, 拿它冒充前者。

例题 7.1 小数据 Bootstrap 手算

样本为 $\{1, 2, 6\}$, 估计量为样本均值 $\hat{\theta} = \bar{x} = 3$ 。某次 Bootstrap 抽到 $B = 4$ 个重抽样本: $(1, 1, 6), (2, 6, 6), (1, 2, 2), (6, 2, 1)$ 。求 $\widehat{se}_B$ 与 $\widehat{Bias}_B$ 。

【解】各重抽样本均值: $\hat{\theta}^* = \frac{8}{3}, \frac{14}{3}, \frac{5}{3}, 3$ 。

$$\bar{\theta}^* = \frac{8/3 + 14/3 + 5/3 + 9/3}{4} = \frac{36/3}{4} = 3.$$

偏差: $\widehat{Bias}_B = 3 - 3 = 0$ (均值估计本来就无偏, 合理)。

标准误: 偏差平方和 $= (\frac{8}{3} - 3)^2 + (\frac{14}{3} - 3)^2 + (\frac{5}{3} - 3)^2 + (3 - 3)^2 = \frac{1}{9} + \frac{25}{9} + \frac{16}{9} = \frac{42}{9}$,

$$\widehat{se}_B = \sqrt{\frac{42/9}{4-1}} = \sqrt{\frac{14}{9}} \approx 1.25.$$

(实际中 $B = 4$ 太小, 仅为演示计算流程。)

例题 7.2 偏差校正的经典例子

用 $\hat{\sigma}^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$ (除 n 版本) 估计方差。已知其偏差为 $-\sigma^2/n$ 。说明 Bootstrap 偏差校正在此的作用。

【解】 $E\hat{\sigma}^2 = \frac{n-1}{n}\sigma^2$, 偏小。Bootstrap 可在不知道理论公式的情况下“测出”这个负偏差: $\bar{\theta}^* - \hat{\theta}$ 会系统性为负, 于是校正值 $2\hat{\theta} - \bar{\theta}^* > \hat{\theta}$, 朝真值方向上调——效果类似把分母 n 改成 $n-1$ 的理论修正, 但 Bootstrap 对任何复杂估计量都通用。

7.3 Jackknife: Bootstrap 的“前辈”

想法。不重抽, 而是每次删掉一个观测: $\hat{\theta}_{(i)}$ 表示删去 x_i 后用剩余 $n-1$ 个数据算的估计, $\bar{\theta}_{(\cdot)} = \frac{1}{n} \sum_i \hat{\theta}_{(i)}$ 。

Jackknife 公式 (必背)

$$\widehat{Bias}_J = (n-1)(\bar{\theta}_{(\cdot)} - \hat{\theta}), \quad \widehat{se}_J = \sqrt{\frac{n-1}{n} \sum_{i=1}^n (\hat{\theta}_{(i)} - \bar{\theta}_{(\cdot)})^2}.$$

系数 $(n-1)$ 的直觉: 删一个点引起的变化只有总偏差的 $\sim 1/(n-1)$, 要放大回去。只需 n 次计算 (Bootstrap 要 B 次), 但对中位数等不光滑的统计量失效; Bootstrap 更通用。

例题 7.3 Jackknife 手算

样本 $\{1, 2, 6\}$, $\hat{\theta} = \bar{x} = 3$ 。求 Jackknife 偏差与标准误。

【解】删一法: $\hat{\theta}_{(1)} = \frac{2+6}{2} = 4$, $\hat{\theta}_{(2)} = \frac{1+6}{2} = 3.5$, $\hat{\theta}_{(3)} = \frac{1+2}{2} = 1.5$; $\bar{\theta}_{(\cdot)} = 3$ 。

$$\widehat{Bias}_J = (3-1)(3-3) = 0 \quad (\text{均值无偏}),$$

$$\widehat{se}_J = \sqrt{\frac{2}{3} [(4-3)^2 + (3.5-3)^2 + (1.5-3)^2]} = \sqrt{\frac{2}{3} \times 3.5} \approx 1.53.$$

对照：均值标准误的经典公式 $s/\sqrt{n} = \sqrt{\frac{(1-3)^2 + (2-3)^2 + (6-3)^2}{2}}/\sqrt{3} = \sqrt{7}/\sqrt{3} \approx 1.53$ ，完全一致——对均值，Jackknife 恰好还原经典公式。

7.4 Bootstrap 置信区间：三种造法

三种区间（置信水平 $1 - \alpha$ ；记 $\hat{\theta}_{(q)}^*$ 为 Bootstrap 估计值的 q 分位数）

1. 正态近似法：假定 $\hat{\theta}$ 近似正态，

$$\hat{\theta} \pm u_{1-\alpha/2} \widehat{se}_B;$$

2. 分位数法 (percentile)：直接取 Bootstrap 分布的两端，

$$[\hat{\theta}_{(\alpha/2)}^*, \hat{\theta}_{(1-\alpha/2)}^*];$$

3. 枢轴量法 (basic/pivotal)：用 $\hat{\theta}^* - \hat{\theta}$ 模拟 $\hat{\theta} - \theta$ 的分布，

$$[2\hat{\theta} - \hat{\theta}_{(1-\alpha/2)}^*, 2\hat{\theta} - \hat{\theta}_{(\alpha/2)}^*].$$

易错点：枢轴量法的”端点翻转”

枢轴量法里上分位数算下限、下分位数算上限（被 $2\hat{\theta}$ 减后大小颠倒）。考试写反端点是重灾区！检验：算完看下限是否 $<$ 上限。

例题 7.4 三种区间数值题

某估计 $\hat{\theta} = 10$ ， $B = 1000$ 次 Bootstrap 得 $\widehat{se}_B = 1.5$ ， $\hat{\theta}_{(0.025)}^* = 7.6$ ， $\hat{\theta}_{(0.975)}^* = 13.2$ 。分别给出三种 95% 置信区间。

【解】正态法： $10 \pm 1.96 \times 1.5 = [7.06, 12.94]$ 。

分位数法： $[7.6, 13.2]$ 。

枢轴量法： $[2 \times 10 - 13.2, 2 \times 10 - 7.6] = [6.8, 12.4]$ 。

注意枢轴量法区间整体向左偏——因为 Bootstrap 分布右偏 ($13.2 - 10 = 3.2 > 10 - 7.6 = 2.4$)，枢轴量法把这种偏斜”反向”扣回，分位数法则照单全收。两者差异正反映了分布的不对称。

7.5 本章考点地图

高频题型清单

1. 默写 Bootstrap 算法及 $\widehat{se}_B, \widehat{Bias}_B, 2\hat{\theta} - \bar{\theta}^*$ （最高频）；
2. 小样本手算：给重抽结果算 se 与偏差（如上例）；
3. Jackknife 公式及手算（注意系数 $n - 1$ 和 $\frac{n-1}{n}$ ）；
4. 三种置信区间的公式与数值计算（枢轴量法端点别写反！）；
5. 概念题：Bootstrap 与 MC 模拟的本质区别；Bootstrap vs Jackknife 优缺点。

8 第7章 EM 算法

8.1 故事：缺一块拼图的极大似然

极大似然估计 (MLE) 的流程很顺：写似然 $\rightarrow$ 求导 $\rightarrow$ 置零解出 $\hat{\theta}$ 。可一旦数据**缺了一块**——有的观测丢失了、或者每个数据”来自哪个子总体”这个标签看不见——似然函数里就会出现”对缺失部分求和/积分”的项，变成一团解不开的对数和 ($\log \sum$)，求导置零没有解析解。

EM 算法 (Expectation–Maximization, Dempster et al. 1977) 的破局思路像”鸡生蛋、蛋生鸡”的迭代：

E 步：假装参数已知，把看不见的缺失信息”猜”出来（求条件期望）；
M 步：假装缺失信息已知，像普通 MLE 一样更新参数（求最大化）。
 两步轮流做，似然只升不降，直到收敛。

8.2 一般框架

记号。 观测数据 X （不完全数据），缺失/隐变量 Z ，完全数据 (X, Z) 的对数似然 $\log L(\theta; X, Z)$ 通常很好优化。

EM 算法（必背）

给定初值 $\theta^{(0)}$ ，第 i 次迭代：

- **E 步**：算 Q 函数——完全数据对数似然在当前参数下对缺失变量的条件期望

$$Q(\theta, \theta^{(i-1)}) = \mathbb{E}_{Z|X, \theta^{(i-1)}} [\log L(\theta; X, Z)];$$

- **M 步**： $\theta^{(i)} = \arg \max_{\theta} Q(\theta, \theta^{(i-1)})$ 。

重复至 $\|\theta^{(i)} - \theta^{(i-1)}\|$ 或似然增量小于阈值。

人话解读

Q 函数看着吓人，其实就一句话：**缺失的部分不知道，就用”当前参数下的最佳猜测”代进去，把完全数据的对数似然变成一个能算的普通函数**。类比填空题：考卷（似然）有几个空（隐变量）看不清，先按目前的理解把空填上（E 步），再按填好的卷子认真作答（M 步）；答完理解加深了，回头重填空、重作答，如此循环，每轮都比上轮更好（单调性）。

两条性质（概念题常考）

1. **单调性**：每次迭代观测数据似然不降， $L(\theta^{(i)}; X) \geq L(\theta^{(i-1)}; X)$ ，故必收敛（似然有上界时）；
2. **局部性**：只保证收敛到驻点/局部最大，不保证全局最优 $\Rightarrow$ 实践中要**多个初值**多跑几次取最优。

考试套路。 EM 大题基本都是同一个剧本：(1) 写出完全数据似然；(2) E 步算出隐变量的条件期望/后验概率；(3) M 步求导得参数更新公式；(4) 也许让你代一步数值。下面用四个经典模型走一

遍。

8.3 例一：两枚硬币（隐标签问题）

例题 8.1 两硬币模型

有 A、B 两枚硬币，正面概率 p_A, p_B 未知。做 n 轮实验：每轮随机摸一枚（不知道摸的是谁），抛 m 次记录正面数 x_i 。写出 EM 算法。

【解】 隐变量 $Z_i \in \{A, B\}$ ：第 i 轮用的是哪枚（设摸到各为 $1/2$ ）。

E 步（贝叶斯公式算“软标签”）：当前参数 $p_A^{(t)}, p_B^{(t)}$ 下，第 i 轮来自 A 的后验概率

$$\mu_i = \frac{\binom{m}{x_i} (p_A^{(t)})^{x_i} (1 - p_A^{(t)})^{m-x_i}}{\binom{m}{x_i} (p_A^{(t)})^{x_i} (1 - p_A^{(t)})^{m-x_i} + \binom{m}{x_i} (p_B^{(t)})^{x_i} (1 - p_B^{(t)})^{m-x_i}}.$$

M 步（按软标签加权的“正面频率”）：

$$p_A^{(t+1)} = \frac{\sum_i \mu_i x_i}{\sum_i \mu_i m}, \quad p_B^{(t+1)} = \frac{\sum_i (1 - \mu_i) x_i}{\sum_i (1 - \mu_i) m}.$$

直觉：若知道标签， $\hat{p}_A$ 就是 A 轮的正面比例；不知道，就按后验概率“打折计票”。

人话解读

“软标签” μ_i 怎么理解？它不是硬说“第 i 轮就是 A 硬币”，而是说“按目前的参数看，这轮有 μ_i 的把握是 A”。于是 M 步计票时，这轮的 x_i 个正面不是全给 A 也不是全给 B，而是按 $\mu_i : (1 - \mu_i)$ 分给两边——就像一笔账说不清是谁的，就按可能性比例分摊。

8.4 例二：多项分布的 197 只动物（经典必考）

例题 8.2 Rao 的遗传学数据

197 只动物分四类，频数 $\mathbf{y} = (y_1, y_2, y_3, y_4) = (125, 18, 20, 34)$ ，概率为

$$\left(\frac{1}{2} + \frac{\theta}{4}, \frac{1 - \theta}{4}, \frac{1 - \theta}{4}, \frac{\theta}{4} \right).$$

直接 MLE 需解二次方程；用 EM 求 θ 。

【解】 拆分技巧：第一类概率 $\frac{1}{2} + \frac{\theta}{4}$ 是“和”，把它拆成两个子类—— z_1 （概率 $\frac{1}{2}$ ，与 θ 无关）和 z_2 （概率 $\frac{\theta}{4}$ ）， $z_1 + z_2 = y_1 = 125$ 。 z_2 即隐变量。

完全数据似然： $L \propto \theta^{z_2+y_4} (1-\theta)^{y_2+y_3}$ ，其 MLE 是漂亮的比例形式 $\hat{\theta} = \frac{z_2+y_4}{z_2+y_4+y_2+y_3}$ 。

E 步：给定 $\theta^{(t)}$ ， $z_2 | y_1 \sim B(125, \frac{\theta^{(t)}/4}{1/2+\theta^{(t)}/4})$ ，

$$z_2^{(t)} = \mathbb{E}[z_2 | y_1] = 125 \cdot \frac{\theta^{(t)}/4}{1/2 + \theta^{(t)}/4} = \frac{125 \theta^{(t)}}{2 + \theta^{(t)}}.$$

M 步：

$$\theta^{(t+1)} = \frac{z_2^{(t)} + 34}{z_2^{(t)} + 34 + 18 + 20} = \frac{z_2^{(t)} + 34}{z_2^{(t)} + 72}.$$

数值演示：取 $\theta^{(0)} = 0.5$ ： $z_2^{(0)} = \frac{62.5}{2.5} = 25$ ， $\theta^{(1)} = \frac{59}{97} \approx 0.608$ ；再迭代 $z_2^{(1)} = \frac{125 \times 0.608}{2.608} \approx 29.15$ ， $\theta^{(2)} \approx \frac{63.15}{101.15} \approx 0.624$ ；……收敛到 $\hat{\theta} \approx 0.627$ 。

8.5 例三：正态样本含缺失值

例题 8.3 缺失数据下估正态参数

$X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$, 但只观测到前 m 个, 后 $n - m$ 个缺失。写出 EM 更新公式。

【解】完全数据 MLE 需要两个充分统计量: $\sum_{i=1}^n x_i$ 和 $\sum_{i=1}^n x_i^2$ 。

E 步: 对缺失的 x_j , 在当前参数下

$$\mathbb{E}[x_j | \cdot] = \mu^{(t)}, \quad \mathbb{E}[x_j^2 | \cdot] = (\mu^{(t)})^2 + (\sigma^{(t)})^2.$$

M 步:

$$\begin{aligned} \mu^{(t+1)} &= \frac{1}{n} \left(\sum_{i=1}^m x_i + (n - m) \mu^{(t)} \right), \\ (\sigma^{(t+1)})^2 &= \frac{1}{n} \left(\sum_{i=1}^m x_i^2 + (n - m) [(\mu^{(t)})^2 + (\sigma^{(t)})^2] \right) - (\mu^{(t+1)})^2. \end{aligned}$$

头号易错点

E 步填补的是**充分统计量的期望**, 不是简单”把缺失值填成 $\mu^{(t)}$ 完事”! $\mathbb{E}[x_j^2] = \mu^2 + \sigma^2 \neq \mu^2$ ——漏掉 σ^2 项会让方差估计系统性偏小。(这正是”填补均值再当完整数据算”这种朴素做法的错误所在。)

8.6 例四：高斯混合模型 (GMM)

背景故事。一群人的身高直方图呈双峰——其实是男女两个正态混在一起:

$$f(x) = \sum_{k=1}^K \pi_k \varphi(x; \mu_k, \sigma_k^2), \quad \sum_k \pi_k = 1.$$

隐变量 Z_i : 第 i 个人属于哪个成分。这是两硬币问题的连续版, EM 的”代表作”。

GMM 的 EM (必背)

E 步: 算责任 (responsibility) ——第 i 个观测属于第 k 成分的后验概率

$$\gamma_{ik} = \frac{\pi_k \varphi(x_i; \mu_k, \sigma_k^2)}{\sum_{l=1}^K \pi_l \varphi(x_i; \mu_l, \sigma_l^2)}.$$

M 步: 按责任加权更新 (记 $N_k = \sum_i \gamma_{ik}$, 第 k 成分的”有效人数”)

$$\pi_k = \frac{N_k}{n}, \quad \mu_k = \frac{1}{N_k} \sum_i \gamma_{ik} x_i, \quad \sigma_k^2 = \frac{1}{N_k} \sum_i \gamma_{ik} (x_i - \mu_k)^2.$$

形式上就是”加权频率、加权均值、加权方差”——非常好记。

例题 8.4 GMM 单步手算

两成分 GMM, 当前参数 $\pi_1 = \pi_2 = 0.5$, $\mu_1 = 0, \mu_2 = 4$, $\sigma_1 = \sigma_2 = 1$ 。对观测 $x = 1$ 算责任 γ_{11}, γ_{12} 。

【解】

$$\gamma_{11} = \frac{0.5\varphi(1;0,1)}{0.5\varphi(1;0,1) + 0.5\varphi(1;4,1)} = \frac{e^{-1/2}}{e^{-1/2} + e^{-9/2}} = \frac{1}{1 + e^{-4}} \approx 0.982,$$

$\gamma_{12} \approx 0.018$ 。 $x = 1$ 离 $\mu_1 = 0$ 近得多, 几乎全部“责任”归第 1 成分。M 步时 $x = 1$ 将以权重 0.982 参与 μ_1 的更新、以 0.018 参与 μ_2 。

8.7 本章考点地图

高频题型清单

1. 默写 EM 框架: Q 函数定义、E/M 两步、单调性与局部最优 (概念 + 简答);
2. 197 动物题: 拆分隐变量、推 E/M 公式、迭代一两步数值 (最经典大题);
3. 两硬币/GMM: 后验概率 (责任) 公式 + 加权更新公式;
4. 缺失正态数据: E 步填充充分统计量 (二阶矩别漏 σ^2 !);
5. 概念题: EM 为什么不会下降? 为什么要多初值? E 步“软分配”与 K-means“硬分配”的关系。

9 模拟试题 (附详细解答)

说明: 覆盖第 1-7 章主要考点, 题型为: 概念简答、算法设计、推导证明、计算题。建议先独立完成再看解答。

一、简答题 (每题 6 分)

1. 叙述逆变换法生成连续型分布随机数的原理与步骤, 并指出其适用前提。
2. 什么是检验的第一类错误、第二类错误与功效? 如何用蒙特卡洛方法估计某检验的功效?
3. 简述 Bootstrap 方法的基本思想, 并说明它与第 3 章“已知总体分布的蒙特卡洛模拟”的区别。
4. 简述 EM 算法的适用场景与 E 步、M 步的含义, 并说明其收敛性质。

二、算法设计题 (每题 10 分)

5. 用逆变换法生成密度为 $f(x) = 3x^2$, $0 < x < 1$ 的随机数, 写出公式与步骤。
6. 设计舍选算法生成 Beta(2, 2) (密度 $p(x) = 6x(1-x)$, $0 < x < 1$) 的随机数: 求最小常数 M 、写出算法、求平均接受概率。
7. 写出生成二维正态 $N_2(\mathbf{0}, \Sigma)$, $\Sigma = \begin{pmatrix} 4 & 3.2 \\ 3.2 & 4 \end{pmatrix}$ (即 $\sigma_1 = \sigma_2 = 2, \rho = 0.8$) 随机向量的变换法步骤。
8. 给出用蒙特卡洛方法估计“ σ 未知时正态均值 t 置信区间覆盖率”的完整算法。

三、推导与计算题 (每题 12 分)

9. 设 $I = \int_0^1 e^x dx$ 。(1) 写出平均值法估计量 $\hat{I}_2$ 并求其方差; (2) 写出对偶变量估计量并说明为何方差更小。

10. 推导控制变量法最优系数 c^* 及最小方差。

11. 数据 1, 3, 5, 统计量为样本均值。(1) 写出 Jackknife 的三个删一均值并计算 $\hat{se}_J$; (2) 叙述 Bootstrap 估计标准误的步骤。

12. 两分量高斯混合模型 $p(x) = \pi\phi(x; \mu_1, 1) + (1 - \pi)\phi(x; \mu_2, 1)$ (方差已知为 1)。写出 EM 的 E 步与 M 步公式。

参考解答

1. 原理: 若 F 连续严格单调, $U \sim U(0, 1)$, 则 $F^{-1}(U) \sim F$ 。因为 $\mathbb{P}(F^{-1}(U) \leq x) = \mathbb{P}(U \leq F(x)) = F(x)$ 。步骤: (i) 产生 $u \sim U(0, 1)$; (ii) 输出 $x = F^{-1}(u)$ 。前提: F 的反函数存在且能显式 (或方便数值) 求出。

2. 第一类错误 (弃真): H_0 真却拒绝, 概率 α ; 第二类错误 (取伪): H_0 假却接受, 概率 β ; 功效 $= 1 - \beta = \mathbb{P}(\text{拒绝 } H_0 \mid H_1)$ 。MC 估计功效: 在 H_1 的某个具体参数下生成容量 n 的样本 $\rightarrow$ 计算检验统计量 $\rightarrow$ 记录是否拒绝; 独立重复 K 次, 功效估计为拒绝频率 (拒绝次数 / K)。

3. Bootstrap: 总体分布未知时, 用经验分布 F_n 代替总体 F , 从原样本中有放回抽取容量 n 的自助样本, 重复 m 次, 用自助统计量 $\hat{\theta}_1^*, \dots, \hat{\theta}_m^*$ 的经验分布近似 $\hat{\theta}$ 的抽样分布。区别: 第 3 章每次从已知总体生成新数据; Bootstrap 只用一份样本反复重抽。

4. 适用: 数据含隐变量/缺失数据, 观测似然难以直接最大化。E 步: 在当前参数下求完整数据对数似然关于隐变量后验分布的条件期望 $Q(\theta, \theta^{(i-1)}) = \mathbb{E}[\log L(Z; \theta) \mid X; \theta^{(i-1)}]$; M 步: $\theta^{(i)} = \arg \max_{\theta} Q(\theta, \theta^{(i-1)})$ 。性质: 观测似然单调不减, 必收敛, 但只保证局部极大、对初值敏感。

5. $F(x) = \int_0^x 3t^2 dt = x^3$ 。令 $u = x^3$ 得 $x = u^{1/3}$ 。步骤: 产生 $u \sim U(0, 1)$, 输出 $x = u^{1/3}$ 。

6. 取建议密度 $f(x) = 1$ ($U(0, 1)$)。 $p(x) = 6x(1-x)$ 在 $x = 1/2$ 取最大 $p(1/2) = 3/2$, 故最小 $M = 3/2$, $h(y) = \frac{p(y)}{M} = 4y(1-y)$ 。算法: (i) 产生 $y \sim U(0, 1)$ 、 $u \sim U(0, 1)$; (ii) 若 $u \leq 4y(1-y)$ 输出 $x = y$, 否则返回 (i)。平均接受概率 $= 1/M = 2/3$ 。

7. (i) 用 Box-Muller 等方法生成独立 $\xi_1, \xi_2 \sim N(0, 1)$; (ii) 令

$$\eta_1 = 2\xi_1, \quad \eta_2 = 2(0.8\xi_1 + \sqrt{1-0.64}\xi_2) = 1.6\xi_1 + 1.2\xi_2.$$

验证: $\text{Var}\eta_1 = \text{Var}\eta_2 = 4$, $\text{Cov}(\eta_1, \eta_2) = 2 \times 1.6 = 3.2$, 正确。

8. 给定真参数 μ_0, σ_0 , 置信水平 $1 - \alpha$: (i) 生成 $X_1, \dots, X_n \sim N(\mu_0, \sigma_0^2)$, 算 $\bar{X}, S$, 得区间 $\bar{X} \pm t_{1-\alpha/2}(n-1)S/\sqrt{n}$; (ii) 记录是否覆盖 μ_0 (即 μ_0 是否落入区间); (iii) 独立重复 K 次, 覆盖率估计 = 覆盖次数 / K , 与 $1 - \alpha$ 比较。

9. (1) $\hat{I}_2 = \frac{1}{n} \sum e^{U_i}$, $U_i \sim U(0, 1)$ 。 $\mathbb{E}e^U = e - 1 = I$; $\mathbb{E}e^{2U} = \frac{e^2-1}{2}$, 故

$$\text{Var}(\hat{I}_2) = \frac{1}{n} \left(\frac{e^2-1}{2} - (e-1)^2 \right) \approx \frac{0.2420}{n}.$$

(2) 对偶估计量 $\hat{I}_a = \frac{1}{2n} \sum [e^{U_i} + e^{1-U_i}]$ 。因 e^x 单调增, e^U 与 e^{1-U} 负相关: $\text{Cov}(e^U, e^{1-U}) = \mathbb{E}e^{U+1-U} - (\mathbb{E}e^U)^2 = e - (e-1)^2 \approx -0.2342 < 0$, 故 $\text{Var}(\hat{I}_a) = \frac{1}{2n} [\text{Var}(e^U) + \text{Cov}(e^U, e^{1-U})] \approx \frac{0.0039}{n}$, 方差缩减约 60 倍。

10. $g(c) = \text{Var}(X - cY) = \text{Var}X - 2c\text{Cov}(X, Y) + c^2\text{Var}Y$ 是 c 的开口向上抛物线, $g'(c) = -2\text{Cov}(X, Y) + 2c\text{Var}Y = 0 \Rightarrow c^* = \frac{\text{Cov}(X, Y)}{\text{Var}Y}$ 。代回:

$$g(c^*) = \text{Var}X - \frac{\text{Cov}^2(X, Y)}{\text{Var}Y} = \text{Var}X (1 - \rho_{XY}^2) \leq \text{Var}X.$$

11. (1) 全样本均值 $\hat{\theta} = 3$ 。删一均值: $\hat{\theta}_{(1)} = \frac{3+5}{2} = 4$, $\hat{\theta}_{(2)} = \frac{1+5}{2} = 3$, $\hat{\theta}_{(3)} = \frac{1+3}{2} = 2$; $\bar{\theta}_{(\cdot)} = 3$ 。

$$\hat{s}e_J = \sqrt{\frac{n-1}{n} \sum_i (\hat{\theta}_{(i)} - 3)^2} = \sqrt{\frac{2}{3} \times (1+0+1)} = \sqrt{4/3} \approx 1.155.$$

(与理论 $S/\sqrt{n} = 2/\sqrt{3}$ 一致。) (2) Bootstrap: 从 $\{1, 3, 5\}$ 中有放回抽 3 个得自助样本, 算均值 $\hat{\theta}_i^*$; 重复 m 次; $\hat{s}e_B = \sqrt{\frac{1}{m-1} \sum (\hat{\theta}_i^* - \hat{\theta}^*)^2}$ 。

12. E 步 (责任):

$$\gamma_i = \frac{\pi^{(t)} \phi(x_i; \mu_1^{(t)}, 1)}{\pi^{(t)} \phi(x_i; \mu_1^{(t)}, 1) + (1 - \pi^{(t)}) \phi(x_i; \mu_2^{(t)}, 1)}.$$

M 步:

$$\pi^{(t+1)} = \frac{1}{n} \sum_i \gamma_i, \quad \mu_1^{(t+1)} = \frac{\sum_i \gamma_i x_i}{\sum_i \gamma_i}, \quad \mu_2^{(t+1)} = \frac{\sum_i (1 - \gamma_i) x_i}{\sum_i (1 - \gamma_i)}.$$

临考三句话

一、抽样三板斧: 逆变换 (解 F^{-1})、舍选 (找 $M = \sup p/f$, 接受率 $1/M$)、变换 (Box-Muller、Gamma 链条)。

二、模拟两件事: 估 α 在 H_0 下生成数据, 估功效在 H_1 下生成数据; 估计量性质 = 重复抽样取均值方差。

三、进阶三招: 方差缩减靠”负相关 / 已知信息 / 重要区域”, Bootstrap 靠”样本代总体有放回”, EM 靠”E 求期望、M 求最大、似然单调不减”。